



硕士学位论文

MASTER'S DISSERTATION

论文题目 基于 WiFi 信道状态信息的室内人员
检测与计数

作者姓名 袁瑞贺
学位类别 工程硕士
指导教师 刘志新 教授

2022 年 5 月

中图分类号：TP181

UDC：621.3

学校代码：10216

密级：公开

工程硕士学位论文

（工程设计型）

基于 WiFi 信道状态信息的 室内人员检测与计数

硕 士 研 究 生：袁瑞贺

导 师：刘志新 教授

副 导 师：张博扬 高工

申 请 学 位：工程硕士

工 程 领 域：控制工程

所 属 学 院：电气工程学院

答 辩 日 期：2022 年 5 月

授予学位单位：燕山大学

A Dissertation in Control Engineering

INDOOR CROWD DETECTION AND COUNTING BASED ON WIFI CHANNEL STATE INFORMATION

by Yuan Ruihe

Supervisor: Professor Liu Zhixin

Yanshan University

May, 2022

燕山大学硕士学位论文原创性声明

本人郑重声明：此处所提交的硕士学位论文《基于 WiFi 信道状态信息的室内人员检测与计数》是本人在导师指导下，在燕山大学攻读硕士学位期间独立进行研究工作所取得的成果。论文中除已注明部分外不包含他人已发表或撰写过的研究成果。对本文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。本声明的法律结果将完全由本人承担。

作者签字：王瑞贺

日期：2022 年 6 月 5 日

燕山大学硕士学位论文使用授权书

《基于 WiFi 信道状态信息的室内人员检测与计数》系本人在燕山大学攻读硕士学位期间在导师指导下完成的硕士学位论文。本论文的研究成果归燕山大学所有，本论文的研究内容不得以其它单位的名义发表。本人完全了解燕山大学关于保存、使用学位论文的规定，同意学校保留并向有关部门送交论文的复印件和电子版本，允许论文被查阅和借阅。本人授权燕山大学，可以采用影印、缩印或其它复制手段保存论文，可以公布论文的全部或部分内容。

保密 ☐，在 年解密后适用本授权书。

本学位论文属于

不保密 ☒。

(请在以上相应方框内打“√”)

作者签名：王瑞贺

日期：2022 年 6 月 5 日

导师签名：刘志刚

日期：2022 年 6 月 5 日

摘要

一个特定区域内的人员数量可以提供很多有价值的信息，而智能家居场景是与我们日常生活息息相关的场景。根据室内人数或占有率能够实时调整供暖通风空调(Heating, Ventilation and Air Conditioning, HVAC)系统及灯光系统等的运行策略，这种基于环境中动态人员数量的智能化控制系统和策略有利于节能环保、降低成本。

本文提出了一个基于 WiFi 信号中信道状态信息(Channel State Information, CSI)的无设备人员计数框架，该框架仅利用现有的 WiFi 基础设施就能以非侵入、低成本和精确的方式实现特定区域的人员计数，且无需环境中的人员携带任何电子设备和他们的主动参与，极大地提高了框架的适用性和扩展性。本文主要研究内容如下：

首先，该框架基于无线信号与检测环境中人数的映射关系提出，即不同数量的人在环境中活动时会对 WiFi 信号造成不同的影响，因此接收端接收到的信号会包含这种差别性的“影响”，所以通过分析接收到的信号便可推测出环境中的人数。

其次，与其他利用所有提取数据进行分析的方案不同，本文框架通过对接收端的数据进行筛选和分析选择了泛化性最好的数据用于后续使用，以获得最佳结果，这有效地减少了数据误差和算法计算成本，并且可以在精炼数据的基础上获得更准确的结果。该框架由以下三个模块组成，分别为信号预处理模块、离线训练模块和在线分类模块。筛选出泛化性最好的数据之后，我们首先通过离散小波变换(Discrete Wavelet Transform, DWT)去噪算法对这些数据进行清洗以实现噪声的滤除，这个阶段的处理可以大幅减少噪声对结果准确性的影响，然后提取并分析了下列四个可以描述人数和信道状态信息数据波动之间关系的特征，分别为方差、平均值、四分位距和均方根值，最后对选定的特征数据进行标记并将其输入到机器学习算法中进行训练和分类。

最后，由于信道状态信息与人数之间具有复杂的非线性关系，本框架通过提取特征并引入机器学习算法的手段将复杂的人数统计问题转化为一个分类问题。实验结果表明本文所提出的人员计数框架能够准确地实现室内区域的人员检测和计数。

关键词：人员计数；无设备检测；机器学习；WiFi；信道状态信息

Abstract

The number of people in a specific area can provide a lot of valuable information, and smart home scenarios are scenarios that are closely related to our daily lives. The operation strategy of HVAC (Heating, Ventilation and Air Conditioning) system and lighting system can be adjusted in real time according to the number of people in the room or the occupancy rate. This intelligent control system and strategy based on the dynamic number of people in the environment is conducive to energy saving, environmental protection and costs reduction.

This paper proposes a device-free crowd counting framework based on CSI (Channel State Information) signals in WiFi signals, which can achieve crowd counting in a specific area in a non-intrusive, low-cost and accurate way using only existing WiFi infrastructure, without the need of carrying any electronic equipment for people in the environment and their active participation, which greatly improves the applicability and scalability of the framework.

First, the framework is based on the mapping relationship between wireless signals and the number of people in the detection environment, that is, different numbers of people will have different effects on the WiFi signals when they are active in the environment, so the signals received by the receiver will contain this differential “influence”, so by analyzing the received signals, it is possible to infer the number of people in the environment.

In addition, unlike other schemes that utilize all the extracted data for analysis, the framework proposed in this paper selects the data with the best generalization for subsequent use by screening and analyzing the data at the receiving end to obtain the best results, where data error and algorithm computational cost are significantly reduced, and more accurate results can be obtained on the basis of the refined data. The framework consists of the following three modules, namely signal preprocessing module, offline training module and online classification module. After filtering out the data with the best generalization, we first clean the data through the DWT (Discrete Wavelet Transform)denoising algorithm to filter out the noise. This stage of processing can greatly reduce the impact of noise on the accuracy

of the results, and then extract and filter the data. The following four characteristics that can describe the relationship between the number of people and the fluctuation of CSI data are analyzed, namely variance, mean, interquartile range and root mean square value, and finally the selected characteristic data is marked and input into the machine learning algorithms for training and classification.

Finally, due to the complex nonlinear relationship between the CSI signals and the number of people, this framework cleverly transforms the complex crowd counting problem into a classification problem by extracting features and introducing machine learning algorithms. The experimental results show that the crowd counting framework proposed in this paper can accurately realize the detection and counting of crowd in indoor areas.

Keywords: Crowd counting; Device-free detection; Machine learning; WiFi; Channel state information

目 录

摘 要.....	I
Abstract	II
第 1 章 绪 论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于红外传感器的人员检测方案.....	2
1.2.2 基于计算机视觉的人员检测方案.....	3
1.2.3 基于环境传感器的人员检测方案.....	4
1.2.4 基于 WiFi 的人员检测方案.....	5
1.3 课题的主要研究内容.....	6
1.4 论文的结构安排与章节划分.....	7
第 2 章 CSI 环境感知技术原理与相关理论.....	9
2.1 WiFi 相关技术.....	9
2.1.1 MIMO 技术.....	9
2.1.2 OFDM 技术.....	9
2.2 无线信号传播模型以及 WiFi 信号特征.....	10
2.2.1 无线信号传播模型.....	10
2.2.2 WiFi 信号特征.....	11
2.3 信道状态信息 CSI 基础与原理.....	11
2.3.1 接收信号强度指示 RSSI.....	11
2.3.2 信道状态信息 CSI.....	13
2.3.3 CSI 与 RSSI 特性的比较.....	14
2.4 CSI 环境感知机器学习算法.....	16
2.4.1 支持向量机算法.....	17
2.4.2 K 近邻算法.....	18
2.4.3 决策树算法.....	19
2.4.4 随机森林算法.....	19
2.5 本章小结.....	20
第 3 章 基于 CSI 的室内人员计数框架的设计.....	21
3.1 框架概述.....	21
3.2 CSI 数据采集与幅值提取.....	22
3.2.1 CSI 数据采集.....	22

目 录

3.2.2 幅值提取	25
3.3 最优数据筛选	27
3.4 数据去噪	29
3.4.1 小波变换	30
3.4.2 基于离散小波变换的去噪算法	32
3.5 属性特征提取	37
3.5.1 分析 CSI 数据的常用特征	37
3.5.2 人员计数特征提取	38
3.6 机器学习分类器	41
3.6.1 超参数调优	41
3.6.2 分类器训练和分类	42
3.7 本章小结	43
第 4 章 实验方案架构与结果性能评估	44
4.1 实验方案架构设计	44
4.2 实验结果性能评估	45
4.2.1 分类器性能评估	45
4.2.2 对比实验	53
4.3 本章小结	54
结 论	55
参考文献	57
攻读硕士学位期间承担的科研任务与主要成果	62
致 谢	63

第1章 绪论

1.1 研究背景与意义

近年来,我们时刻都在见证着无线传感技术的快速发展和无处不在的应用,这些技术包括 WiFi、射频识别(Radio Frequency Identification, RFID)以及超宽带(Ultra-Wideband, UWB)等,这在很大程度上促进了环境感知的应用,如定位、手势识别、跌倒检测以及本文所研究的人数估计等^[1-3]。在现实生活中,一个特定区域的人数对许多应用场景来说是至关重要的。在智能家居的应用场景中,根据房间内的人数自动控制照明系统和调整采暖通风空调(Heating, Ventilating and Air Conditioning, HVAC)系统意义重大^[4],因为相对于传统控制方法,这种智能化的控制系统可以减少电能损耗,从而促进节能环保^[5];在消防救援等紧急场景下,消防员的人身安全需要得到保证,随时获取到环境中的人员数量至关重要^[6];在商场消费或其他商业区域的场景下,管理人员可以根据门店区域内的人数随时调整销售策略,及时地引导消费者以改善其消费体验,最终使商家利润最大化^[7]。这些场景是广泛存在的,以往的解决方案是派遣更多的人力投入到这些工作中,这不仅效率低下,而且浪费成本,相反,如今的无线环境感知技术使得这些应用场景智能化的实现成为可能。

在目前的很多研究方案中,研究人员使用红外传感器、摄像头、移动设备和射频信号等来实现人员计数。对于红外传感器方案,部署在房屋门顶部的红外传感器可以用来分别计算进入室内和离开房屋的人数,从而间接得到室内人数^[8]。然而,该方案很难处理多人同时进入或离开房间的情况,这将导致其准确率急剧下降。对于摄像头方案,由于图像识别技术发展成熟,所以基于计算机视觉的人员计数方法也是使用最普遍的方案之一^[9],但图像处理算法同时导致了巨大的计算成本,此外,摄像头的工作必须依赖于良好的照明条件,其性能会受到遮挡和覆盖的严重影响而使得效果大打折扣,另外值得注意的是,有些人不喜欢总是被监视,因为他们担心自己的隐私可能被暴露。至于基于设备的方法,如 RFID、蓝牙和手机等,这些方法要求室内人员携带额外的电子设备,如 RFID 标签和移动设备等,甚至要求人员主动参与实验,这将阻碍系统的大规模应用和进一步扩展^[10-12]。众所周知,在如今的办公室、实验室和其他室内环境中, WiFi 基础设施已经无处不在,这为室内无线传感提供了极为有利的条件。因此, WiFi 已经成为最方便、最普遍的室内无线传感技术^[13],而且大多数

基于设备的方案是通过 WiFi 信号实现的。应用最为广泛的 WiFi 信号有两种，一种是接收信号强度指示(Received Signal Strength Indicator, RSSI)，另一种是信道状态信息(Channel State Information, CSI)。根据文献[14]可知，RSSI 是一种粗糙的测量指标，因为它随着时间的推移会有很大的波动；相反，CSI 是一种来自于物理层的细粒度信道指标，能够通过分析正交频分复用(Orthogonal Frequency Division Multiplexing, OFDM)子载波来显示信号是如何从发射器传播到接收器的。因此，CSI 是以无设备和保护隐私的方式进行人员计数工作的一个更优秀的指标。由以上讨论可知，人员数量在诸多方面都有重要应用，所以本文的研究方向和内容具有不可忽视的重要意义。

1.2 国内外研究现状

近年来，无线感知技术快速发展，受到了大量研究人员的青睐，知名的研究团队主要来自于清华大学、香港科技大学、麻省理工学院以及各个研究所等国内外知名院校和科研院所^[15]，同时，一些用于检测和计算人员数量的无线感知方案如雨后春笋般出现，总体上这些方案可以被分为以下几个类别：(1) 基于红外传感器的方法；(2) 基于摄像头的方法；(3) 基于环境传感器的方法以及(4) 基于 WiFi 的方法。在这一节中，将说明上述应用于人员计数方案的优点和缺点，并主要分析本文所使用的 WiFi 技术的特点。

1.2.1 基于红外传感器的人员检测方案

基于红外传感器的方案是最常用的人数统计方法之一^[16]，红外线传感器通过检测人体辐射的能量来探测人的存在。然而，它只能解决一个人是否存在或在检测区域内行走的情况，这意味着当更多的人同时出现在场景中时，它是无效的。虽然红外传感器的功耗低，部署方便^[17]，但在探测范围和对多人共存的敏感度方面，它的作用极为有限。此外，红外传感器只是提供粗略的二进制信息^[18]，通常不足以分析人数。文献[16]提出了一种基于物体温度信号中的累积和变化检测的人数检测方法，利用检测到的温差中不同平均温度的关联性以及与红外传感器的决策融合形成一个人数估计方案。在文献[17]中，作者在传感器中引入了旋转遮板形成了旋转遮板式传感器以探索其在运动感应之外的功能，因为传统的红外传感器只能检测运动人员，在该文献中，传感器实现了静止的个体定位、跟踪和运动方向的检测，更具体地说，通过检测和分析由旋转遮板引起的非线性红外能量流的极性相位，能够对静止的个体进行区

域级定位。通过进一步分析输出的占空比,可以预测人员的方向。文献[18]主要对三种具有不同分辨率的热成像传感器进行了系统研究并对三种传感器的性能进行了并列比较,重点是传感器的特性、估计算法和占用率估计性能的比较分析,并最终提出了一个统一的占用率估计处理算法流程,此外该文献还为传感器数据的预处理、特征提取和占用率估计算法的微调提出了一些具体算法,然而,该文献只能实现占有率的估计,并不能具体估计检测环境中的人数。

使用红外传感器的方案缺点也很明显,该传感器本身只能通过检测环境中的热源来间接实现人员的检测,想要实现更为精确的人数检测,需要在传感器的基础之上扩展其他硬件配合使用,常见的组合系统为红外传感器和 WiFi 信号的结合,然而,这种组合使得系统变得臃肿复杂,难以部署和推广。

1.2.2 基于计算机视觉的人员检测方案

基于摄像头的人员计数方案是目前流行且成熟的人员检测和计数方法之一^[19]。研究人员通过分析相机拍摄的图像,能够得到检测环境中精确的人数。但连续的视觉监控所捕获的极其巨大的数据量会导致后续繁重的计算,这可能会提高通信负荷,使得该方法本身的效率降低^[20]。此外,当涉及到摄像机固有的死角造成的有限探测范围问题时,它也有与红外传感器相同的缺点。然而,基于摄像头的方法的其他致命缺点包括对光线的敏感性和对隐私的侵犯,因为人们通常不愿意被周围的摄像头所监控^[21]。文献[19]通过利用摄像机捕获的互补信息在摄像机之间传递监测状态以解决人数统计的困难并提高性能,最终提出了一个新的双通道框架用于计算环境中的人数,其中多个摄像头提供了不同的主体视图^[22]。在该文献中,作者将视觉特征的视角标准化和估计人群的大小视为一个联合学习问题,得出可扩展的计数模型,提供比现有方法更准确的结果,然后引入了一种算法,在不同相机拍摄的图像中匹配行人群体,实现多个相机可以一起工作而不必担心它们之间的差异。文献[20]提出了一种使用一组具有重叠的摄像机同时跟踪密集人群中的所有人员的方法。为了克服遮挡问题,摄像机被放置在高处并且只跟踪人的头部。由于每个前景区域可能由多个主体组成,所以头部检测仍然是困难的。通过结合几个视图的数据,高度信息被提取出来并用于头部图像的分割,实现了头部的检测^[23]。该方法在具有挑战性的光照条件下对室内和室外环境进行了测试,结果表现良好。

以上文献致力于解决基于计算机视觉的人数检测方案中的缺陷,但是即使这样,也难以克服摄像头对环境的苛刻要求和繁重的计算量问题,而且基于视觉的方案一般会配合深度学习使用,常用的算法为卷积神经网络,因为这些深度学习算法更适合图像的处理,然而带来的代价就是长时间的网络训练和算法复杂度的提升。

1.2.3 基于环境传感器的人员检测方案

必须指出的是,常用的环境传感器如二氧化碳传感器、温度和湿度传感器以及光传感器的用途已经被扩展,用于室内环境下的人员检测和计数^[24]。以二氧化碳传感器为例,有人提出了一些算法来建立二氧化碳浓度和人数之间的关系^[25]。二氧化碳传感器的主要缺陷是,由于二氧化碳在空气中扩散缓慢,而且不稳定,所以实时性差,精确度低^[26]。文献[25]提出了一种利用视频数据和二氧化碳浓度相结合来检测室内环境居住者人数的方法,通过将视频数据和二氧化碳浓度检测到的居住者人数进行相互校准以提高检测精度。与传统室内环境人数监控系统相比,基于居住者人数的预测控制可以实现更快的响应,节约更多的能源。作者进行了模拟和实验研究来验证基于二氧化碳传感器的室内人数计算方案的可行性和有效性,结果表明,该系统可以实现总能耗节省 39.4%。通过实验和模拟,验证了所提出的基于占用人数的预测控制是一种有前途的技术,可以在确保热舒适和室内空气质量的同时,节省供暖、通风和空调系统的能源消耗。在文献[26]中,作者使用来自光、温度、湿度和二氧化碳传感器的数据来预测办公室的占用率,并使用开源程序通过不同的统计分类模型进行了评估,该文献中的研究使用了三个数据集,一个用于训练,两个用于测试,通过训练线性判别分析、分类和回归树以及随机森林模型,获得最佳准确度,结果表明,正确选择特征以及适当的分类模型可以对准确度预测产生重要影响。文献[27]开发了一个根据室内二氧化碳浓度来估计室内实时占用者数量和室内占用率的估计器,该估计器是一个占用水平的动态模型,为了确定该动态模型,作者提出了一种名为特征缩放极端学习机的算法,它是标准极端学习机的一个变体和扩展,而且被证明在占用率估计问题上表现更好。此外,对二氧化碳数据进行预平滑处理可以极大地提高估计的准确性,然而,在实际应用中目前存在的一个问题是无法获得实时的全局平滑的二氧化碳数据,所以作者提供了一种使用局部平滑的二氧化碳数据的方法,并且这种数据可以实时获得。此外,作者还引入了一个新的标准,即公差精度,以评估占用率,这也是本文的贡献之一。

以上方案缺陷明显,这是因为环境传感器难以稳定运行,会受到诸多环境因素的影响,导致其准确率急剧下降,而且环境传感器采集的数据也难以建立科学的模型。

1.2.4 基于 WiFi 的人员检测方案

WiFi 技术已经在许多领域得到了广泛的应用,这其中包括室内人员检测和计数,因为 WiFi 基础设施总是部署在室内环境中,而且几乎每个移动设备都配备了 WiFi 模块^[28]。基于 WiFi 的人员检测和计数可以分为两类,分别是基于设备的方法和无设备的方法。前者依靠设备或标签如手机和 RFID 标签来实现人员计数。至于后者,则是利用和分析无线信号来建立人数与无线信号之间的关系,这使得该方法更有利于推广和商业化,因为人们不必携带电子设备甚至主动参与计数过程。同时,该方法还可以有效保护人们的隐私,这也是本文使用 WiFi 技术的原因之一。

此外, RSS 与 CSI 类似,也是无线传感领域特别是室内定位和人员计数领域常用的指标^[29]。尽管现有文献中已经提出了一些基于 RSS 的无设备人员统计方案^[30,31],但 RSS 本身是一个粗略的测量,并受到多径的影响,这使得它很难提供人数统计的准确性。恰恰相反,与 RSS 相比,CSI 可以提供细粒度的信道信息,因为它来自于物理层,它的每个子载波的振幅和相位信息都包含着环境中的人员情况。

文献[32]提出了利用一对 WiFi 发射器和接收器采集 WiFi 信道状态信息并利用 CSI 数据以无设备的方式推断人群数量的方案。该文所提出的方法通过深度神经网络建立了 CSI 数据波动和人员数量之间的关系,然后应用训练好的深度神经网络模型去估算环境中的人员数量。文献[33]提出了一种基于信道状态信息的无设备人群计数框架,该框架的设计源于人们日常的观察,即 CSI 对环境的变化高度敏感,就像青蛙的眼睛一样,作者从理论上阐述了活跃人员的数量和 CSI 变化之间的直观关系。设计该框架的一个重大困难是找到一个函数来描述人员数量和 CSI 的各种特征之间的关系,为此,作者提出了一个度量,即非零元素的百分比来扩展 CSI 矩阵。这种单调关系可以通过 Grey Verhulst 模型来明确表述,该模型可用于人群计数且不需要进行费时费力的现场调查。作者使用现有的支持 IEEE 802.11n 协议的设备来实现提出的框架,并通过在现实场景中进行广泛的实验来评估其性能,最终的结果表明,提出的框架以很好的准确性、可扩展性和可靠性实现了人员计数。文献[34]中,作者提出了 CrossCount,这是一个基于深度学习的精确的人员计数方案,它使用单一的 WiFi 通信链路来估计检测区域的人员数量。其主要思想是将时间上的链接阻塞模式作为

一种识别特征，从而提供一个无处不在的、准确的人员计数系统。作为该系统设计的一部分，CrossCount 解决了一些深度学习的挑战，如类的不平衡和训练数据的增加，以提高模型的可推广性。CrossCount 在多个测试平台上的实施和评估表明，它能够以 100% 的准确率实现最多 2 个人的计数精度，这表明 CrossCount 可以实现小数量的人员计数，但是多人检测还无法实现。

上述方案尽管都可以实现检测区域内的人员计数，但是每个方案都有其局限性，有的方案能够检测的人数太少，这不利于其进一步的推广，有的方案需要大量算力的支持才可以保证其准确率，这无法实现快速的识别，也难以推广普及，所以急需一种方便使用、推广简单和能耗低的方案来实现检测区域的人员计数，这正是本文研究的目的及本文创新所在。

1.3 课题的主要研究内容

在本文中，我们提出了一个基于 CSI 的无设备人员计数框架，仅利用一个商业现成的 WiFi 路由器和一台微型计算机就能以非侵入、低成本和精确的方式实现人员计数。人员计数是通过分析从子载波中提取的 CSI 数据实现的，不需要环境中的人员随身携带任何电子设备，并且不会收集与人有关的私人信息。与要求人员随身携带额外的传感器或手机的传统人员计数系统相比，本文提出的框架更为便捷且可扩展性更强。此外，在这个框架中只利用了现有的室内 WiFi 基础设施。对于我们的方法来说，它不仅可以检测到区域内有无活动的人，还可以估计出具体的人数，其整体的人员计数准确率可以达到 87.2%。

本文选择接收端中泛化性最好的数据进行分析以获得最佳结果。首先，选择在实验室的真实环境里进行实验，利用路由器和微型计算机收集 CSI 数据。在获得数据后，利用基于离散小波变换的去噪方法对获得的原始 CSI 数据进行噪声滤除。通过分析去噪后的数据，我们发现了一个现象，即来自不同发射天线的 CSI 测量值表现出不同的性能。因此，通过绘制不同天线接收信号的曲线图以选择在接收端表现最好的数据。根据选定的数据，提取了以下四个特征进行下一步处理，分别为方差、平均值、四分位距和均方根值，每个特征都可以描述 CSI 数据与特定区域内人数之间的关系。由于所获得的关系不能准确区分更多的人，所以这些特征随后被输入到机器学习算法中进行训练，最后得到了一个可以用来估计特定区域内人数的训练模型。最终，通过混淆矩阵、接收者操作特征(Receiver Operating Characteristic, ROC)曲线和精

精度-召回(Precision-Recall, PR)曲线等性能评估指标对框架进行了评估,结果显示本文所提出的框架可以准确地计算出检测环境中的人数,此外,相比于基于深度学习的方案 DeepCount^[47]来说,本文所提出的框架准确率更高,计算成本更低。

1.4 论文的结构安排与章节划分

本文的主要内容是使用 WiFi 中的 CSI 信号解决室内环境下人员检测和计数问题,本文内容的结构安排如下:

第1章:本章首先说明了本文的研究背景和研究意义,指出了无处不在的 WiFi 技术极大促进了无线感知领域的发展,尤其是室内定位、行为检测如跌倒检测以及本文所研究的室内人数估计,然后描述了不同的无线感知技术在人员计数方面的国内外发展现状,同时指出了本文研究具有重要的实际意义,最后介绍了本文的研究内容和章节结构安排。

第2章:本章介绍了 CSI 环境感知技术的基本原理和相关技术理论,包括通信技术中常用的多输入多输出技术、OFDM 技术、无线信号传播模型以及 WiFi 信号的传播特征,然后分别阐述了人员计数领域常用的两大信号指标即 RSSI 和 CSI,并对比了两者的特性和优缺点,根据二者的优缺点,本文选择 CSI 作为采集信号,接着分别介绍了常用于 CSI 环境感知领域的机器学习算法,包括支持向量机算法、随机森林算法、K 近邻算法和决策树算法,本文也使用上述机器学习算法来实现分类。

第3章:针对本文研究的主要内容,详细阐述了本文提出的 CSI 人员计数框架的构建过程,首先概述了框架的总体结构,然后介绍了 CSI 数据采集和幅值提取的过程,其次本文提出了最优数据筛选策略来选择泛化性能最好的数据用于后续分析和训练,以降低机器学习模型的复杂度并提高框架最终的准确率,这也是本文的创新之一,随后介绍了本文基于离散小波变换(Discrete Wavelet Transform, DWT)的去噪环节和特征提取环节,最终阐述了具体的机器学习训练和分类过程。

第4章:本章主要介绍了本文的实验方案架构和最终结果的性能评估,首先介绍了本文的实验环境和软硬件配置,然后分别使用多维的性能评价指标对分类结果进行了全方位的评估,结果显示本文所提出的框架可以准确地估算检测环境中的人员数量,最后将本文框架与基于深度学习的人员计数方案 DeepCount 进行了对比,结果显示本框架性能表现优于该方案。

结论：最后对本文内容进行总结分析，并对本文提出的基于 CSI 的人员计数框架进行总体概述。同时，结合算法的优缺点，分析算法可以改进的地方，并对后续工作进行进一步展望。

本文研究由浅入深，循序渐进，章节结构可用图 1-1 所示流程图来描述：

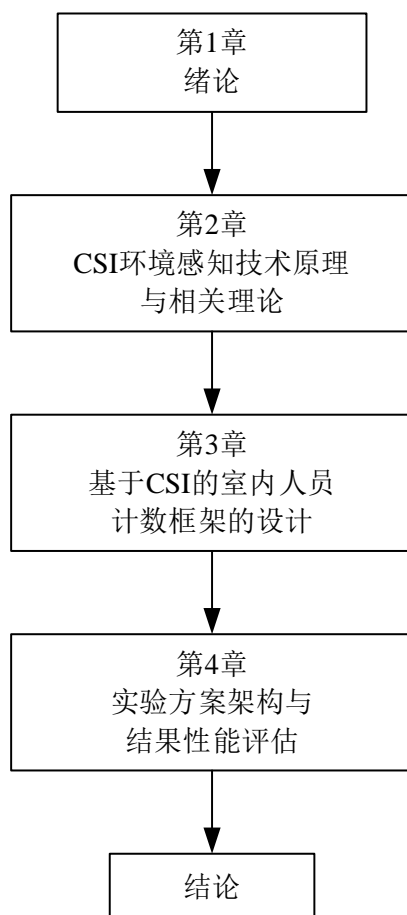


图 1-1 本文章节结构图

第2章 CSI 环境感知技术原理与相关理论

2.1 WiFi 相关技术

2.1.1 MIMO 技术

多输入多输出技术(Multi-Input Multi-Output, MIMO)首先通过信号发射端的多根天线分别独立地发送信号,然后在接收端通过多根天线接收并复原初始信号,这一过程的主要原理是该技术建立了一个数学模型来描述无线通信系统中的多天线通信行为^[35]。MIMO 技术可以做到大幅地增加系统的输入输出量,使得信号传播更远,且不需要增加额外网络资源,所以 MIMO 技术在近几年的无线通信领域取得了长足的发展和大量的应用^[36]。此外,相对于其余单输入或单输出的通信技术, MIMO 可以提高信道容量,提高信道可靠性^[37]。SISO、SIMO、MISO 和 MIMO 传输示意图如图 2-1 所示,其中, Tx 表示信号发射端, Rx 表示信号接收端。

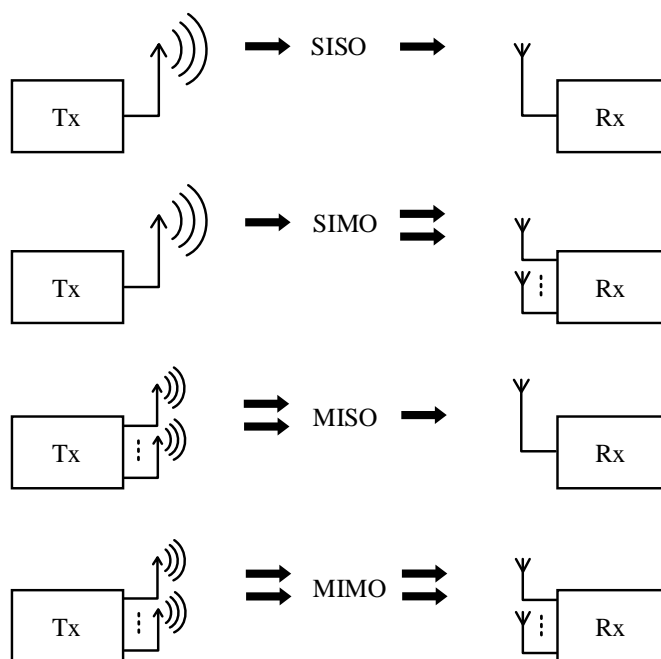


图 2-1 四种输入输出技术传输示意图

2.1.2 OFDM 技术

OFDM 技术,即正交频分复用技术,是一种多载波传输技术,它会将频谱切割成多个子载波,且使每个子载波相互正交,将串行高速数据进行并行传输是该技术的

主要特点之一，OFDM 技术能够大大提高传输效率，有效抵抗多径衰落，优势明显[38]。该技术在发送端将信号置于频域上，随后给信号添加周期性的 prefix 并发送出去，在接收端移除信号的 prefix，最后再通过傅里叶变换转换为时域信号，这就是该技术的原理概述[39]。其工作流程如图 2-2 所示。

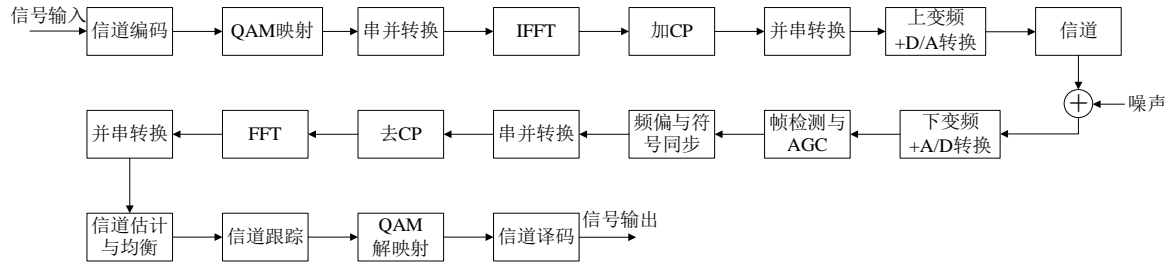


图 2-2 OFDM 工作流程图

本文通过采集信道状态信息 CSI 并分析 CSI 的幅值信息实现人员检测和人员计数，现有的路由器基本都支持 OFDM 技术，将信号调制后发送出去，采集到的 CSI 信号中有 30 个子载波，每个子载波都反映着信道的状态，本文正是利用这一特性来做分析。

2.2 无线信号传播模型以及 WiFi 信号特征

2.2.1 无线信号传播模型

无线信号在传播过程中会随着传播路径的增加、障碍物的存在等各种因素而发生衰减，但是在介质分布均匀的自由空间中，由于不存在任何遮挡物，电磁波的传播不会经历反射、散射和绕射等情况而只有直射传播，无线电功率只会因为传播过程中能量的扩散而逐渐变小，根据电磁学定律的自由空间传播模型可知[40]，距离发射天线 d 处的接收信号的功率 P_R 可表示为公式(2-1)：

$$P_R(d) = \frac{P_T G_T G_R \lambda^2}{(4\pi)^2 d^2 L} \quad (2-1)$$

式中， P_T 为天线的发射功率，不同天线数值不同； G_T 为发射天线的增益参数，一般是固定值； G_R 为接收天线的增益参数，同样是固定值； L 为系统损耗因数，一般为常数，与无线信号的传播过程无关； λ 为波长，单位为米。由以上公式可以推出，在距离天线为 d 米处的信号的接收功率与发射接收天线间的距离可以用一个函数来描述，接收到的信号功率随着发射接收天线二者之间的距离的平方成反比例地衰减。

2.2.2 WiFi 信号特征

在现实生活中,自由空间是不存在的,环境中存在很多阻碍物,以实验室为例,桌子、椅子、柜子和各种实验器材等都会阻挡信号传播,使信号发生反射、散射和绕射,而 WiFi 信号属于无线信号的范畴,因此 WiFi 信号的传播具有这种传播特征^[41]。

反射是指无线信号在传播的过程中遇到阻碍物表面时改变原先的传播路径,沿着另外的传播路径到达终点的现象,但是阻碍物波长要大于该信号自身波长;绕射也称为衍射,是指无线信号在传播过程中遇到阻碍物时从该物体的边缘部分绕过去传播的现象,其中障碍物波长与信号的波长几乎相等;散射是指无线信号在传播过程中遇到在单位体积内的数量极其庞大的阻碍物时发生的传播现象^[42],该障碍物波长小于信号的波长。无线信号在传播过程中发生的上述三种现象如图 2-3 所示。

基于以上无线信号传播分析可以得知,当信号到达接收端的时候,与发射端发射的原始信号相比,能量会大打折扣,也就是说传输的信号丢失了很多关键信息,对于问题的分析造成了很大的影响。




图 2-3 无线信号传播过程中发生反射、散射和绕射现象

2.3 信道状态信息 CSI 基础与原理

2.3.1 接收信号强度指示 RSSI

在介绍信道状态信息 CSI 之前,有必要先介绍另一个常用于无线感知领域的指标——RSSI。利用 WiFi 信号进行环境感知的基本原理是人员在环境中的动作和活动

会改变信号的传播特征,从而导致发射端和接收端的信号出现差异,因此可以通过分析这种差异进行环境感知,常见的应用包括室内定位、动作识别、呼吸及心率检测、人数检测和人群计数等^[43]。RSSI 是科研人员最早使用并使用最为广泛的一种指标,它来自媒体访问控制(Media Access Control, MAC)层,不仅可以从 WiFi 网络中获取,也存在于多种无线通信网络如蜂窝信号网络和蓝牙信号中, RSSI 也可以表示各自的信号强度,由此可见, RSSI 适用范围广泛^[44]。此外, RSSI 值的大小在一定程度上还可以反映信道质量的好坏,且容易获取,只需在采集设备上安装一个简易的软件就可以采集周围环境中辐射的无线信号的 RSSI。

在室内环境下传播的无线信号具有非理想化的特征,由于障碍物和人员的存在会导致室内环境变得不同于自由空间,信号从发射机发出后经过反射、散射和衍射等情况后会改变传播路径,使得信号的原始幅值和相位发生改变,信号也会分散到多条传播路径继续传播,经过这样的过程后,不同路径到达接收机的时间就会出现差异,进而导致时延^[45]。RSSI 表示的是信号经过多条路径传播的累积情况,如图 2-4 所示。




图 2-4 多路径信号叠加

假设无线信号在室内环境中的传播路径的数目为 N , 则接收机接收到的信号强度表示为如下公式:

$$V = \sum_{i=1}^N \|V_i\| \cdot e^{-j\theta_i} \quad (2-2)$$

式中, N 表示无线信号传播路径的数量, V_i 表示第 i 条路径所传播信号的振幅, θ_i 表示第 i 条路径所传播信号的相位。由以上公式可推知, 接收信号强度指示 RSSI 可表示为如下公式:

$$RSSI = 10 \log_2 (\|V\|^2) \quad (2-3)$$

此外, RSSI 还可以通过路径损耗模型来表示, RSSI 和无线信号传播距离 d 的关系可用如下公式表示:

$$RSSI_{PL}(d) = RSSI_0 - 10\alpha \lg \frac{d}{d_0} + e \quad (2-4)$$

式中, $RSSI_{PL}$ 表示信号经过从发射端到接收端的过程后最终的强度, d 表示接收端和发射端之间的距离, α 表示信号采集附近环境的不确定因子, 一般在 2~4 之间取值, d_0 表示参考距离, e 表示无线信号在传播过程中的随机误差, 可以忽略不考虑。

RSSI 是一个相对来说比较粗糙的指标, 因为它只能表示信号在传播过程中的功率能量大小, 无法反映更加细粒度的信息, 所以 RSSI 一般用于室内定位或较大幅度动作的识别, 并且精确度有限, 因此研究人员开始寻找新的能够反映 WiFi 信号中更为细粒度信息的指标。

2.3.2 信道状态信息 CSI

在无线通信领域中, 信道状态信息 CSI 可以揭示通信信道的传输特性, 它描述了信号从发射器传播到接收器的过程, 并代表了反射、散射、衍射和随距离衰减的一种叠加效果。如今, 几乎所有的商用 WiFi 路由器都配备了用于多输入多输出通信的多根天线, 并在物理层利用支持 IEEE 802.11n 标准的 OFDM 技术, 将整个网络频谱分为正交的子载波。因此, 当信号在每个发射器和接收器天线对之间传播时, CSI 可以揭示通信链路的细粒度信息, 包括每个子载波的时间延迟、幅值和相位^[46]。因此, 通过分析 CSI 数据的信息, 能够准确地实现定位和人员计数等应用。

发射天线和接收天线之间的 WiFi 信号在时域上可以被模拟为信道脉冲响应(CIR) $h(\tau)$, 可以用如下公式表示:

$$h(\tau) = \sum_{i=1}^N a_i e^{-j\theta_i} \delta(\tau - \tau_i) \quad (2-5)$$

式中, N 表示传播路径数量的和, $\delta(\tau)$ 是 Dirac delta 函数^[47], a_i 、 θ_i 和 τ 分别代表第 i 条路径的幅值、相位和时延。

相应地, 在频域中, CSI 可被模拟为信道频率响应(CFR), 用如下公式表示:

$$H(k) = \|H(k)\| e^{j\angle H(k)} \quad (2-6)$$

式中, $H(k)$ 和 $\angle H(k)$ 分别表示第 k 个子载波处 CSI 的振幅和相位。5300 无线网卡收集的原始 CSI 数据是一个 $m*n*s$ 的复数矩阵, 其中 m 是发射链路的数量, 通常为发射天线的数量, n 是接收链路的数量, 通常为接收天线的数量, s 是 Intel 5300 网卡收集的子载波的数量。在每组 CSI 数据中, 有 $m*n$ 个数据链路, 每个数据链路包括 30 个子载波。从中提取的 CSI 矩阵如公式(2-7)所示:

$$CSI = \begin{bmatrix} H_{1,1} & H_{1,2} & \cdots & H_{1,30} \\ H_{2,1} & H_{2,2} & \cdots & H_{2,30} \\ \vdots & \vdots & \ddots & \vdots \\ H_{m \times n,1} & H_{m \times n,2} & \cdots & H_{m \times n,30} \end{bmatrix} \quad (2-7)$$

式中， $H_{p,q}$ 代表第 p 个数据流中第 q 个子载波上的 CSI 数据。

2.3.3 CSI 与 RSSI 特性的比较

在 OFDM 技术的加持之下，CSI 能够获得 WiFi 信号中 RSSI 无法获得的更加细粒度的底层信息。二者之间的详细比较如表 2-1 所示：

表 2-1 CSI 与 RSSI 的比较

比较的特性	RSSI	CSI
所在层级	介质访问控制层	物理层
稳定性	较低	高
准确度	较低	高
分辨率	较低	高
适用范围	比较有限	较广
获取难度	容易	困难
区分多径能力	不能	可以

尽管 RSSI 包含的信息少，是一种粗略的信号表示，但是 RSSI 也有其用武之地，也可以反映通信链路的质量，而且 RSSI 容易获得，门槛低，在多数路由器设备和移动设备上就可以得到该值。

对于 CSI 而言，它是一种可以更精确地反映信道通信状况的细粒度指标，经研究，CSI 在稳定的环境中可以保持稳定的状态，这一点本文也进行了验证，同时，CSI 也会察觉环境的改变并给出反馈，由此可见，其特性很适合本文的研究。但是 CSI 的采集并不是很容易，具有一定的门槛，只有少数网卡如 Intel 5300 网卡才能采集到 CSI 信号，此外就是定制化的硬件设备且安装了相应的网卡和驱动，对硬件设备有一定的约束性，这也成为制约其发展的因素之一。

详细来说，科研工作者越来越喜欢使用 CSI 这一指标用于室内定位、动作识别和人数检测等应用的原因主要是 CSI 具有以下两个方面的优越性。

(1) CSI 具有更好的稳定性。

由上文可知, RSSI 仅仅是对传播信号经过反射、散射和绕射等现象后多条传播路径的叠加计算, 是一个平均值, 即使当环境发生微小的变动, RSSI 值也会受到影响而强烈波动, 相关研究表明, 稳定环境下的 RSSI 也会有较大的波动, 这是该信号与生俱来的缺陷, 如果是细粒度要求的实验, 这个值在平稳环境中是难以接受的, 会导致结果出现较大的偏差。与此相反, 用于采集 CSI 信号的路由器采用了 OFDM 技术, 在 OFDM 对输入信号进行正交分解的过程中引入了循环前缀技术来对载波干扰进行抑制, 这就使得 CSI 信号对比 RSSI 更加稳定。CSI 幅值大小随数据包的采集时间序列变化情况如图 2-5 所示, 其中, X 轴表示数据包的时间序列序号, Y 轴表示子载波索引, Z 轴表示 CSI 幅值大小。




图 2-5 CSI 信号的幅值随数据包时间序列的变化趋势

由上图可知, 在稳定环境下, 随着采集的数据包数量的增加, 也就是说, 随着时间的推移, 对于每个子载波而言, 其 CSI 幅值并没有发生剧烈的变化(几乎不变), 而是保持了较为稳定的状态, 这直接说明了相对于 RSS 信号来说 CSI 信号具有无与伦比的稳定性。

(2) CSI 相对 RSSI 是更为细粒度的指标。

RSSI 与 CSI 之间的关系可以形象地理解为白光和彩虹，如图 2-6 所示，白光表示的是粗略的信息，无法得知其中的细粒度信息，而彩虹是通过三棱镜将白光分解后而得到的多色光，包含着更多的信息，OFDM 技术恰好可以充当这个“三棱镜”。

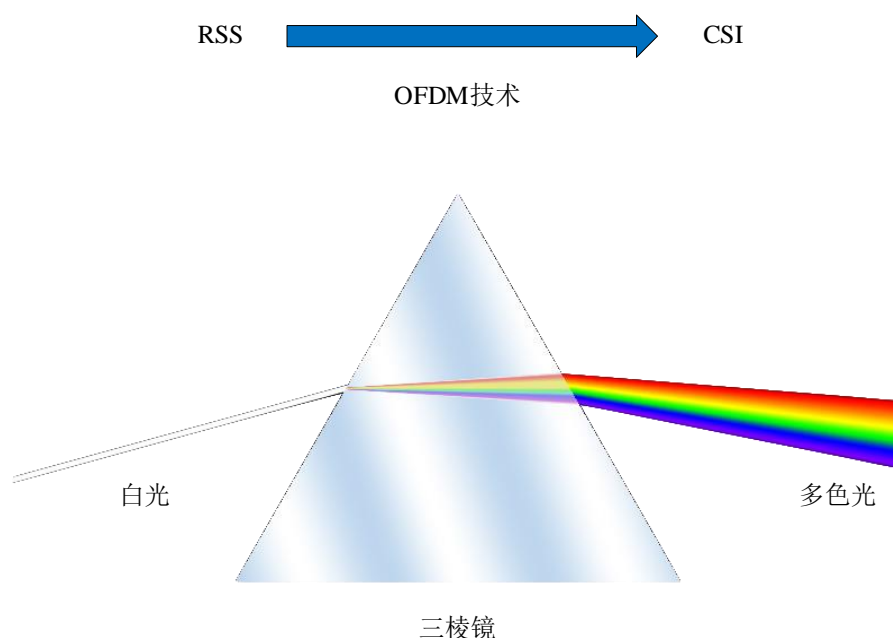


图 2-6 RSS 与 CSI 之间关系的形象比喻

2.4 CSI 环境感知机器学习算法

机器学习(Machine Learning, ML)算法在环境感知领域中应用非常广泛，机器学习赋予了机器“学习”的能力，机器学习的主要内涵为通过对一组已知数据进行学习并获得其中的规律，使得机器能够预测未知数据中的规律，实现智能化地推理和预测。机器学习主要分为以下几个类别：有监督学习、无监督学习、半监督学习以及强化学习^[48]。

有监督学习主要通过将数据集划分为训练集和测试集并人为给训练集数据打上标签的方法让机器“学习”数据的规律并最终产生一个模型，然后使用该模型预测新数据的特征^[49]，常见的有监督机器学习算法有以下几种，主要包括支持向量机(Support Vector Machine, SVM)算法、K 近邻(K-Nearest Neighbors, KNN)算法、随机森林(Random Forest, RF)算法和决策树(Decision Tree, DT)算法。本文主要使用有监督机器学习算法中的四种常用算法对提取的特征数据进行学习并实现特征的分类，后续将逐一介绍本文用到的机器学习算法。

无监督学习与有监督学习是一对相对的概念，主要区别为无监督学习中的训练集不会被打标签^[50]，输入数据后，它会自动对数据进行分类，常用的无监督机器学习算法主要为聚类算法，包括 k-means 聚类、DBSCAN 聚类等。

半监督学习是处于前面叙述的两种学习方式之间的一种机器学习^[51]，是二者的结合体，该学习方式中的数据集部分进行打标签，部分无任何标注。

强化学习(Reinforcement Learning, RL)基于环境提供的奖励或惩罚做出行动并最终取得最大化利益^[52]，无需对数据进行标注，强化学习运作的过程是一个探索的过程，最终得到最优解，常用的强化学习算法主要为 Q-Learning。

2.4.1 支持向量机算法

支持向量机最初设计是一种用于二分类的机器学习模型，但是随着需求的增长，二分类难以适应最新的发展，于是人们开发了新的方法使 SVM 支持多分类，常用的方法为一对多法(one versus rest, 1-v-r SVM)，本质上还是二分类，只不过是剩余的样本整体视为一个类，本文使用的就是这种方法来实现多分类的需求。

分类问题可以分为线性问题和非线性问题，如图 2-7 所示，SVM 可以同时解决线性分类问题和非线性分类问题，其核心原理是将低维样本数据映射到高维空间，然后寻找一个分类超平面，使得两类样本分布在该超平面两侧并且距离超平面尽可能远，这样分类器具有良好的泛化能力^[53]，其原理如图 2-8 所示，线性不可分数据通过核函数可以转换到三维空间，最常用的核函数为高斯核函数，这样可以提高模型的适用范围，图 2-8 中的阴影平面就是分界超平面，如果从侧面看，效果和图 2-7 中的线性可分问题相同，这样就把问题转化成了线性可分问题，解决了线性不可分问题。




图 2-7 线性可分问题与线性不可分问题


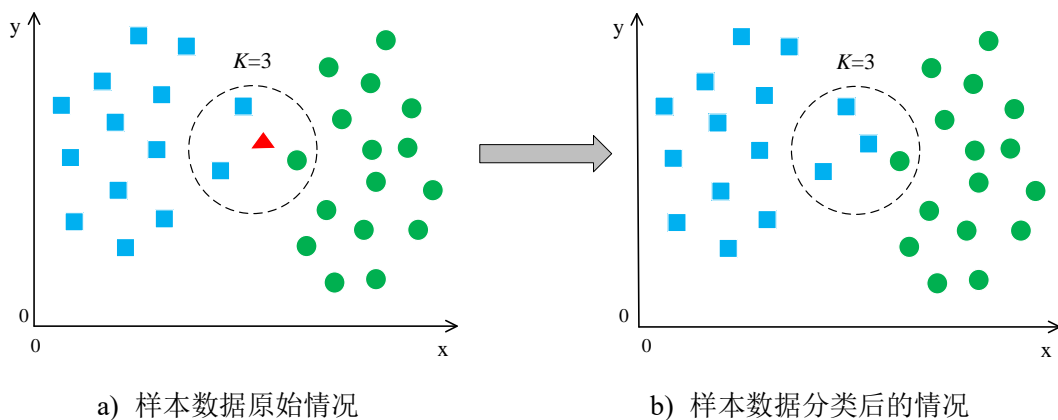
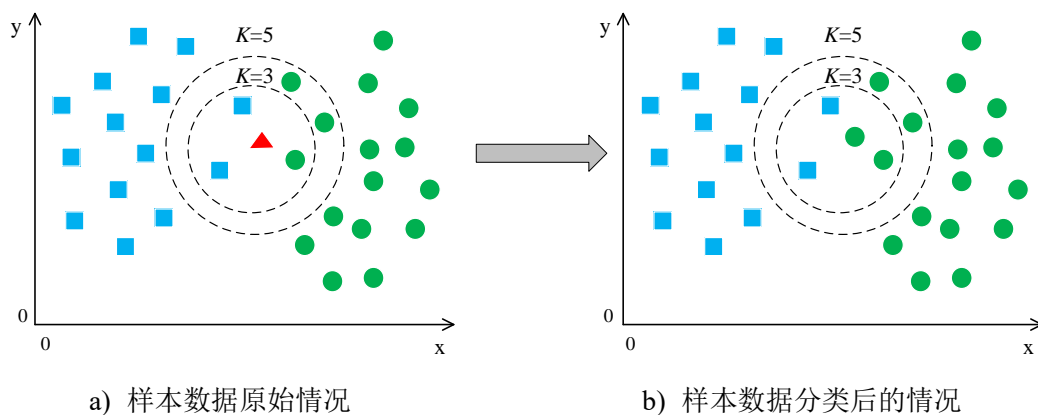


图 2-8 SVM 工作原理

2.4.2 K 近邻算法

KNN 算法是机器学习中最为基础和常用的一种算法，顾名思义，该算法就是寻找样本点附近的 K 个最近的“邻居”来评估样本点属于哪一类别^[54]，其核心是 K 值的选取，不同的 K 值会导致不同的判断结果，其判断过程如图 2-9 和 2-10 所示。

图 2-9 K 值取 3 时的分类情况图 2-10 K 值取 5 时的分类情况

由图 2-9 可知, 当 K 值取 3 时, 距离样本点最近的三个数据中有两个是蓝色方块, 所以判定样本点属于蓝色方; 而由图 2-10 可知, 当 K 值取 5 时, 距离样本点最近的五个数据中有三个是绿色方块, 所以判定样本点属于绿色方块。以上图示说明了 KNN 的运作原理, 那么 K 值是如何选取的呐? 最常用的方法是交叉验证, 即将样本数据按照一定的比例拆分成训练数据集和验证数据集, 从选取一个较小的 K 值开始, 不断增大 K 值, 并观察分类效果, 直到找到一个比较合适的 K 值为止。

除了 K 值的选取之外, 距离的计算也很重要, 因为只有计算出距离才能选取最近的点作为参照, KNN 中最常用的距离度量方式为欧氏距离, 使用公式(2-8)计算:

$$L(x, y) = \sqrt[p]{(|x_1 - y_1|)^p + (|x_2 - y_2|)^p + \cdots + (|x_n - y_n|)^p} = \sqrt[p]{\sum_{i=1}^n (|x_i - y_i|)^p} \quad (2-8)$$

式中, x_i 和 y_i 分别代表两个 n 维向量, p 值不同代表不同的距离度量方式, 当 $p=2$ 时使用的就是欧几里得距离的度量模式。本文使用的 KNN 算法中的 K 值为 3。

2.4.3 决策树算法

决策树算法是一种采用树形结构的简单机器学习算法, 实现容易, 具有高度的可解释性, 完全符合人的直观思维方式, 应用非常广泛^[55]。该算法通过一层一层的推理来解决分类问题, 其结构如图 2-11 所示。




图 2-11 决策树算法的树形结构

由图 2-11 可知, 决策树主要由三种元素节点组成, 它们分别是根节点、内部节点和叶节点。根节点即最顶部的节点, 包含所有样本数据; 内部节点对应属性判断的中转过程, 即并不是最终的决策结果; 叶节点代表最终的决策结果, 即叶节点后不再有其他节点。在内部节点给定一个属性值进行判断, 根据结果判断应该进一步进入哪个流程, 直到到达叶节点处, 得到决策结果, 流程终止。

2.4.4 随机森林算法

随机森林算法是在决策树算法的基础之上衍生出来的集成学习算法, 能够在很大程度上解决决策树算法的过拟合问题, 它由多个决策树构成且各个决策树之间互

相没有关联。当输入样本特征解决分类问题的时候,算法会遍历森林中的每一棵树使其依次进行决策和分类,每个决策树最终会输出一个自己的分类结果,而最终的结果来自于各个决策树分类结果中最多的结果,这个过程随机森林会自动完成^[56]。除了解决分类问题外,随机森林还可以解决回归和聚类问题。随机森林算法结构如图 2-12 所示。本文所使用的随机森林算法的决策树数量为 10。

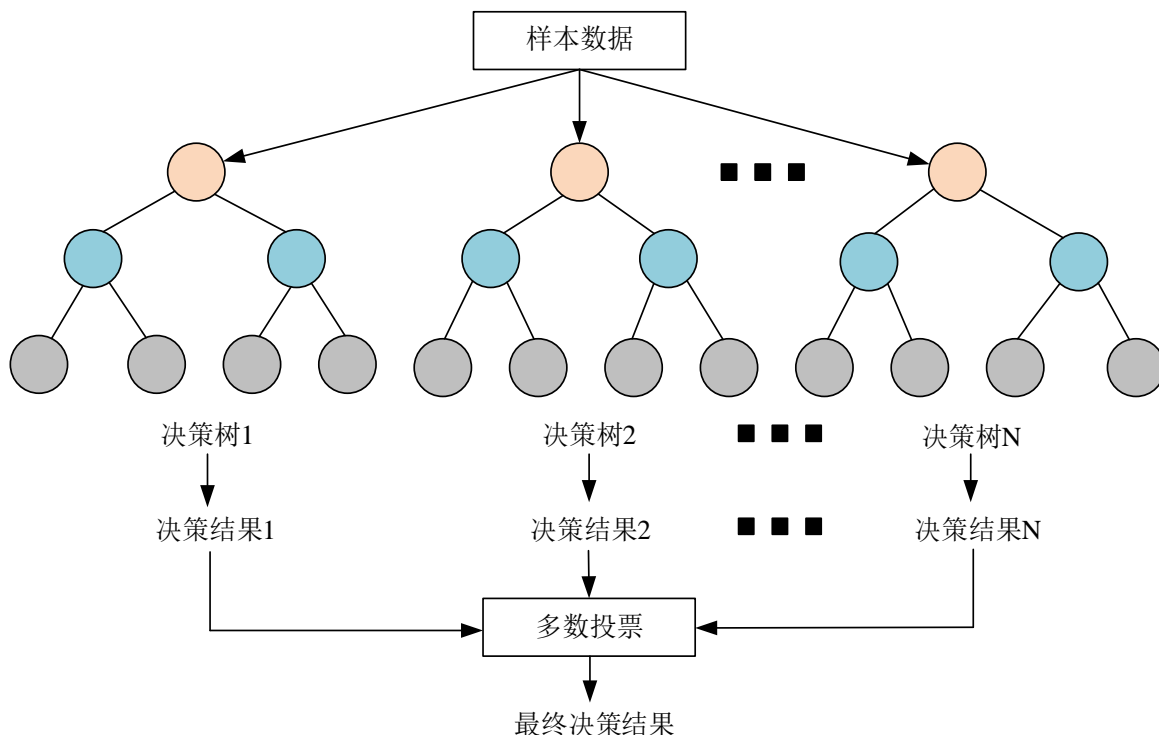


图 2-12 随机森林算法结构示意图

2.5 本章小结

在这一章中,主要阐述了 CSI 环境感知技术原理与相关理论,首先介绍了现代路由器的 MIMO 技术和 OFDM 技术,然后介绍了无线信号传播模型和 WiFi 信号的特征,为后续 CSI 物理量的展开做了铺垫。紧接着引入了本文使用的物理量信道状态信息,分别详细介绍了传统指标接收信号强度 RSSI、更为细粒度的指标 CSI、CSI 数据采集平台的搭建和 CSI 的采集以及 RSSI 与 CSI 的详细对比,凸显了 CSI 的优越性,最终选择 CSI 作为主要的指标。最后,简要阐述了用于 CSI 环境感知的机器学习算法并详细介绍了本文所使用的有监督机器学习中的四种机器学习算法,为后文做了铺垫。

第3章 基于CSI的室内人员计数框架的设计

3.1 框架概述

本文提出了基于CSI的室内人员计数框架，使用该框架可以有效地对室内特定环境下的人员进行计数，并且具有准确率高、能耗低、无隐私侵犯风险和易于实施等优点，该框架主要分为三个模块，框架结构如图3-1所示。

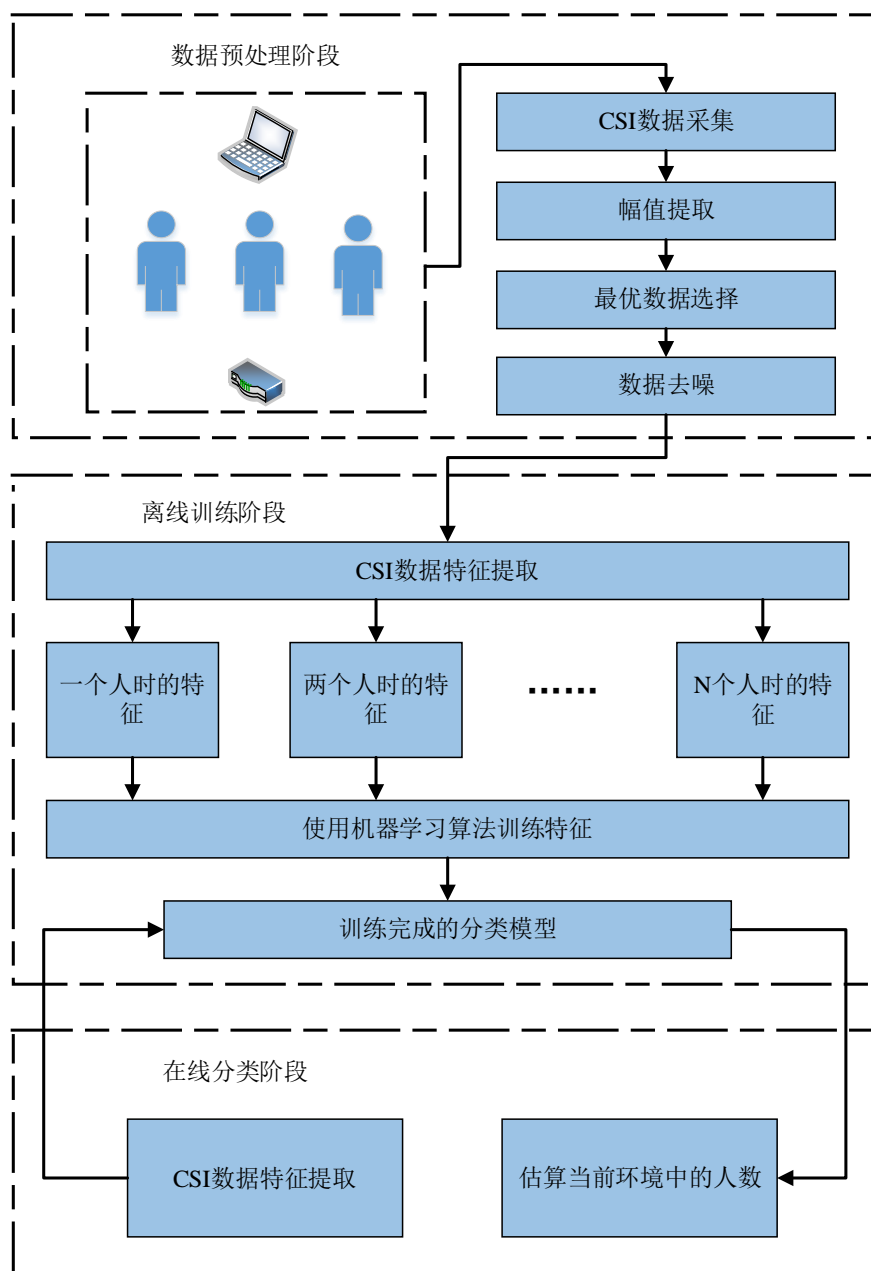


图3-1 基于CSI的室内人员计数框架结构示意图

由图 3-1 可知,该框架由三个模块组成,分别为:数据预处理模块、离线训练模块和在线分类模块。其中,第一个模块包含以下几个部分,分别为:CSI 数据采集、幅值提取、最优数据筛选和数据去噪,其中,采集的 CSI 数据包括幅值数据和相位数据,但是相位数据一般不用于人数估计,因此我们只对幅值数据进行提取,六条通信链路的通信质量受到不同接收天线、通信环境等因素的影响,为了保证真实的通信环境,所以通信环境无法人为干预,但是可以分析不同的接收天线接收到的 CSI 数据的质量来选择泛化性最好的数据用于后续分析;第二个模块主要对 CSI 数据进行属性特征提取,主要是提取能够表征人数差别的属性特征,由于特征数据与环境中的人数无固定的线性关系,所以这是一个非线性问题,我们决定使用机器学习方法对特征数据进行训练,这种方法能够有效地解决非线性问题,随后使用多种机器学习算法对特征进行训练,学习其中的规律和特点,生成所需模型;第三个模块使用离线阶段训练好的模型对新数据进行识别分类,输出的类别即为环境中的人数。此外,该框架仅由两个设备组成,包括一个配备了两根天线作为发射机的 WiFi 路由器和一个配备了 Intel 5300 无线网卡的迷你电脑,其中包含三根天线用于接收发射天线的信号,这也表明了本文所提出的框架无需环境中的人员携带额外的电子设备,所以不存在对人员造成隐私侵犯的风险。

该框架是一个基于 CSI 的无设备人员计数系统,此处的无设备指的是人员无需携带额外的设备,该框架可以准确地计算出特定环境中的人数,而不需要大量的实验工作。在该框架中,CSI 数据来自现有的商用 WiFi 基础设施,即如今广泛部署于办公室、实验室等室内环境的路由器设备。

3.2 CSI 数据采集与幅值提取

3.2.1 CSI 数据采集

不同于 RSSI,CSI 来自于物理层,普通网卡无法访问,最初获取 CSI 需要专业的采集仪器,但是造价昂贵,难以推广和普及,所以近年来科研人员通过在商用无线网卡上修改驱动的方法使无线网卡具备采集 CSI 的能力。目前支持采集 CSI 信号的无线网卡主要有两款,一种是 Intel 5300 网卡,另一种是 Atheros 9000 系列无线网卡,虽然 Atheros 系列无线网卡采集到的 CSI 数据包含的信息更加全面且稳定性更好,但是没有 Intel 系列的网卡商用普遍,所以 Intel 无线网卡被更多人使用。所以此实验我们选用 Intel 5300 网卡作为采集 CSI 数据的工具,Intel 5300 无线网卡如图 3-2 所示。




图 3-2 Intel 5300 网卡(左侧为通用款, 右侧为半高款)

如图 3-2 所示, Intel 5300 网卡共有两种形式, 根据采集平台硬件的兼容性, 本文选用的是半高款, 此外, CSI 数据采集平台如图 3-3 和 3-4 所示。



图 3-3 CSI 数据采集平台(发射机)



图 3-4 CSI 数据采集平台(接收机)

如图 3-3 和 3-4 所示, 发射器为一台 TP-LINK WR841N 双天线路由器, 工作频段为 2.4GHz, 接收器为一台占美 HT770 迷你主机, 将原装网卡替换为 Intel 5300 网卡并安装配套的三根外接天线, 这样就形成了 6 条数据传输链路。在主机中安装 Linux 系统, 具体发行版本为 Ubuntu 14.04.4 LTS, 然后安装 CSI 采集软件 Linux 802.11n CSITool^[57], 该软件由华盛顿大学的研究人员 D.Halperin 开发并开源, 目前绝大多数使用 CSI 这一指标量的研究工作都是用该软件采集 CSI 数据。

CSITool 一共支持四种工作模式, 分别为: Client 模式、AP 模式、IBSS(ad-hoc)模式和 Monitor 模式, 目前所见的工作中最常用的是 AP 模式和 Monitor 模式, 一般情况下, 多台主机之间互相传输数据适合使用 Monitor 模式, 在该工作模式之下, 主机可以互相充当发射机和接收机, 使用更加灵活, Monitor 模式的优点是不易波动, 在发送数据包时可以设置具体的数量, 并且可以设置它们的时间间隔以及传输信号的信道和使用的带宽等不同的定制化参数, 多种参数都可以根据实验需求灵活设置, 缺点是成本高, 因为多台主机之间需要部署多个 5300 无线网卡用于数据的收发, 而本实验中只有一台主机, 且 AP 模式设置更加简单, 但缺点是接收的数据包的数量是不可控的, 但是这并不影响 CSI 数据的获取和最终实验结果的精度, 而且使用 AP 模式更加节约成本, 所以本文选择使用 AP 模式。

使用 Linux 802.11n CSITool 采集到的数据并非是可以直接使用的 CSI 数据, 而是一种特殊的数据结构, 包含着很多信息, 其中 CSI 数据混在其中, 这种数据结构包含的信息如表 3-1 所示, 由表可知, 该数据结构中一共包含 12 种信息, 不仅显示了发射机和接收机天线的数量, 而且还包含接收端接收到的 RSSI 值, 但是本文并不需要使用 RSSI 信号, 因为 RSSI 值是一种粗粒度的指标, 准确率较低。

表 3-1 接收端采集到包含 CSI 数据的数据结构中各个参数的含义

名称	含义
timestamp_low	无线网卡时钟的低 32 位
bfee_count	波束成型测量值的总数
Ntx	发射端发射天线的数量
Nrx	接收端接收天线的数量
rss_i_a	第一根天线的 RSSI 值
rss_i_b	第二根天线的 RSSI 值
rss_i_c	第三根天线的 RSSI 值
csi	信道状态信息矩阵
noise	噪声功率
agc	自动增益控制
perm	天线与射频链路间关系系数
rate	发射数据包的速率

3.2.2 幅值提取

由表 3-1 可知, 其中的 CSI 就是我们所需的信道状态信息数据, 提取该矩阵需要使用专门的工具, 该工具是 Linux 802.11n CSI Tool 提供的 Linux 802.11n CSI Tool Supplementary, 该工具包含了处理 CSI 数据基本的 MATLAB 代码, 我们需要根据自己的需求对代码进行修改以实现定制化的功能, 我们已经通过修改代码的方式提取了 CSI 数据中的幅值信息用于后续分析, 这是因为在表征人数变动这一方面, 幅值比相位更具有表现力。

信号会随环境中阻挡物数量的不同而发生不同程度的波动, 同样, CSI 数据曲线也会随人数多少呈现不同程度的分散。因此可以推断出, 如果检测到环境中没有人出现, CSI 数据曲线将保持稳定和平稳的状态, 如果有更多的人踏入监测区域, 曲线将出现明显的波动。基于上述分析, 可以提取 CSI 数据的幅值信息进行分析, 并以此推断环境中的人数。利用上述认知, 即不同数量的人在环境中活动时对 WiFi 信号有不同的影响, 可以用 CSI 曲线来描述人数, 以探索人的数量和 CSI 数据之间的关系。

当检测区域内没有人、有一个人和有多个人时，30 个子载波上实际测量的 CSI 幅值分别如图 3-5、图 3-6 和图 3-7 所示。




图 3-5 监测区域无人时的 CSI 幅值曲线

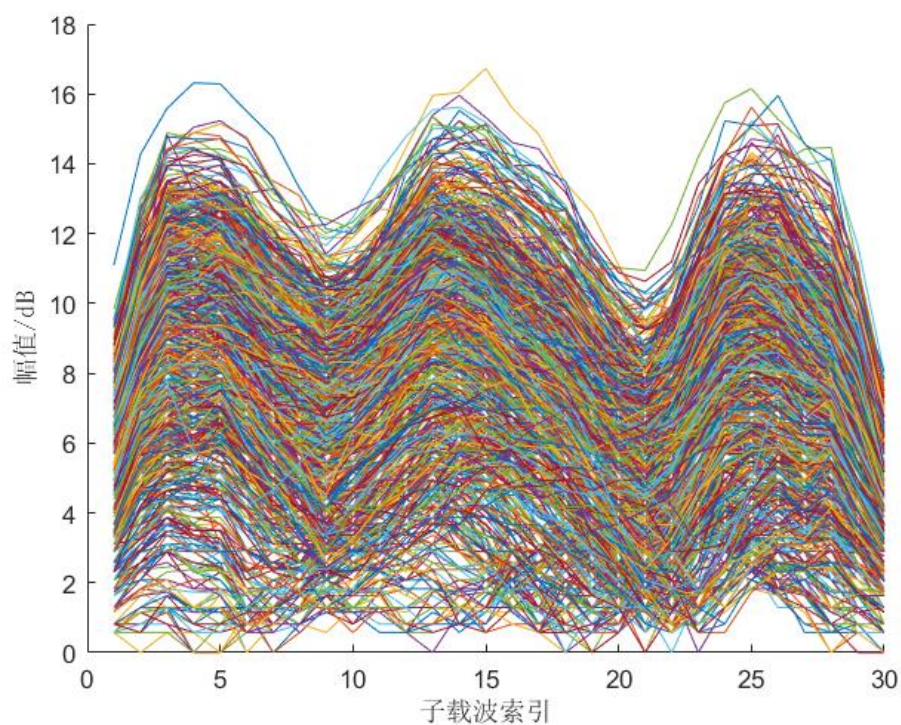


图 3-6 监测区域有一个人时的 CSI 幅值曲线




图 3-7 监测区域有多个人时的 CSI 幅值曲线

从图 3-5 中可以看出,当检测区域内无人时,CSI 幅值保持明显的稳定状态,波动范围较小。然而,当检测区域内出现一个人员时,CSI 幅值相较于之前会有明显的变化,如图 3-6 所示,波动值基本维持在最大为 15dB 附近。此外,在图 3-7 中,可以看到在检测区域内出现多个人时,CSI 幅值的波动接近 30dB,大幅增长。这种变化趋势符合我们的日常认知经验,定性地说明了 CSI 数据波动程度与人数的关联性,所以通过分析 CSI 数据曲线的波动情况可以推测检测环境中的人员数量,为我们进一步的研究提供了更有力的支撑。

3.3 最优数据筛选

由前述可知,接收端有三根天线用于接收 CSI 数据,我们绘制了稳定环境下即环境中无人时三根天线上接收的 CSI 数据曲线图,分别如图 3-8、图 3-9 和图 3-10 所示,因为在稳定环境下波动最小的数据可视为最为优秀的数据,使用这样的数据更能准确的反映环境中的真实情况。从曲线图中可以发现,与其他两根天线相比,第二根接收天线上的 CSI 数据的波动性更小。此外,三个接收天线上的数据的方差如图 3-11 所示。从结果可以看出,接收信号受不同天线的影

如前所述，通过观察接收到的 CSI 数据的波动程度可以推断出环境中的人员数量。因此，基于这种想法，我们选择三根接收天线上方差最小的 CSI 数据，因为该数据最能够反映环境的稳定程度。因此，可以保证我们选择了最好的数据进行实验。




图 3-8 接收端第一根天线接收到的 CSI 数据




图 3-9 接收端第二根天线接收到的 CSI 数据




图 3-10 接收端第三根天线接收到的 CSI 数据




图 3-11 接收端三根天线分别接收到 CSI 数据幅值的方差

3.4 数据去噪

尽管 CSI 是一个细粒度的信号指标, 包含比 RSSI 更加丰富的信息, 但从设备获得的 CSI 原始信号中也存在其他的噪声, 需要进一步滤除, 因为现实中的环境要比

理想空间复杂得多，在复杂的室内环境中，以我们的实验室为例，如图 3-12 所示，各种障碍物，包括具有不同高度和形状的桌子、椅子和柜子等以及其他可以发射干扰射频信号的电子设备将导致不同种类的噪声。




图 3-12 实验室示意图

3.4.1 小波变换

从傅里叶变换到短时傅里叶变换，再到小波变换，不同的方法在处理信号时的时间和频率分辨率示意图如图 3-13 所示。

从图中可以发现，相比于原始的时序数据集，不同处理方法的时频分辨率有一定的区别，其中，块的大小和方向表示分辨率的大小。原始时间序列在时域能够以较高分辨率处理数据，在频域则没有分辨率；使用傅里叶变换就可以很好地处理信号中的噪声，前提是信号频率与时间无关，但是如果信号越不稳定，越具有动态特性，傅里叶变换的效果就越差，也就是说它可以准确地让我们知道信号中存在哪些频率，但不能让我们找到这些频率出现的时间位置；短时傅里叶变换在频域和时域都具有大小相等的分辨率；分析动态信号的更好方法是使用小波变换而不是傅里叶变换，因为小波变换在频域和时域都具有比较高的分辨率，使用小波变换不仅可以发现信号中存在哪些频率，而且还可以知道这些频率出现的时间，这是因为在小波变换中，小频率值的频域分辨率较高且时域分辨率较低，大频率值的频域分辨率较低且时域分辨率

较高,所以我们可以使用具有大比例窗口的信号来分析“大”特征,使用具有更小比例尺的信号以分析更“小”的特征,这就是小波变换的优势,它权衡了不同尺度的频率^[58]。由于本文中的 CSI 数据动态变化较强烈,是时间序列的数据,更适合使用小波变换来处理以发现更多的数据特征。




图 3-13 不同信号处理方法的时间和频率分辨率示意图

为进一步说明正弦波和小波这两种波的区别,我们绘制了二者的示意图,如图 3-14 所示,其中,上面为正弦波,下面为小波。




图 3-14 正弦波和小波的区别

傅里叶变换将输入信号和一系列正弦波相乘来分析信号中存在的频率成分，用到的正弦波具有不同的频率，因此输出信号是通过正弦波的线性组合来表示的；同样地，小波变换则是使用一系列称为小波的函数乘以输入信号来分析信号，每个小波函数都有不同的尺度。

由图 3-14 可以看出，正弦波无限长，而小波是局部范围的信号，正弦波从负无穷延伸到正无穷，不是在时间上固定的，而小波是在时间上固定的，只出现于某一时间区间，这允许小波变换在获得频率信息的基础上还可以获得额外的时间信息。

小波函数分为很多类型，比如在 PyWavelets 库中包含 14 个小波类型，类型彼此不同，形状也不同，因为每个类型的小波在各个方面如波峰间隔都做出了不同的取舍，所以我们在处理信号时可以依据自身需求选取不同种类的小波以达到最满意的效果，由于一个小波函数必须满足的数学条件只有两个，即归一化和正交化，所以很容易就可以生成一个新的小波^[59]。

如前所述，小波分为离散小波和连续小波两种类型，所以相应地，小波变换也分为两种类型，一种是离散型小波变换，另一种是连续型小波变换，其中，连续小波变换由公式(3-1)表示：

$$X_w(a,b) = \frac{1}{|a|^{1/2}} \int_{-\infty}^{+\infty} x(t) \bar{\varphi}\left(\frac{t-b}{a}\right) dt \quad (3-1)$$

式中， $\bar{\varphi}(t)$ 是连续母小波， a 是缩放因子， b 是平移因子，缩放因子和平移因子的值是连续的，换句话说，两个因子取值不同就可以有无数的小波，所以理论上使用小波变换可以实现任意需求的效果。

3.4.2 基于离散小波变换的去噪算法

由前述可知，相对于傅里叶变换和短时傅里叶变换，小波变换在信号处理领域有着得天独厚的优势。原始信号经过小波变换之后得到的信号和噪声在不同尺度上表现出不同的特征，根据这些特征，真实信号的小波系数会随着尺度的增大而逐渐增大，而噪声的小波系数会迅速衰减，将含有噪声的信号通过多尺度分析后，噪声的高频系数变为 0 或控制在某个范围内，再通过小波重构算法还原最初的原始信号，这就是小波去噪的基本原理^[60]。因此，在本文中，基于小波变换的去噪方案被用来净化通信链路中每个子载波的原始 CSI 以过滤噪声。基于小波变换的阈值去噪算法的原理流程如图 3-15 所示。

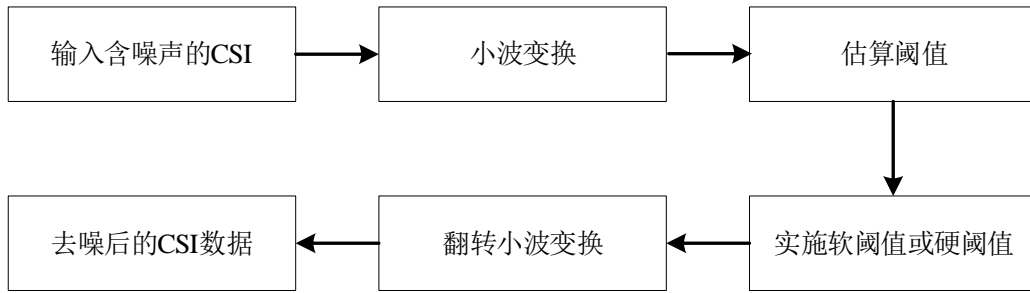


图 3-15 基于小波变换的去噪算法工作流程图

利用小波阈值去噪的主要思路如下，需要提前设置一个临界值 λ ，并将该值作为阈值。小波变换后得到小波分解系数 $w_{j,k}$ ，将该系数与上述临界值进行比较，如果小波系数 $w_{j,k}$ 小于 λ ，则判断该系数是噪声造成的，需要移除这部分系数；若 $w_{j,k}$ 大于 λ ，则判断该系数是由信号造成的，需要保留下来，在最后得到去噪信号之前，需要对经过处理后的小波系数进行小波重构计算^[61]。具体步骤如下：

- (1) 实施小波变换，对含有噪声的原始信号 $x(t)$ 进行处理，输出一系列小波分解系数 $w_{j,k}$ ；
- (2) 使用阈值处理函数对上一步得到的小波分解系数进行阈值处理，得到小波估计系数 $\bar{w}_{j,k}$ ，使得绝对值 $\|\bar{w}_{j,k} - w_{j,k}\|$ 尽可能小；
- (3) 得到小波估计系数之后，实施小波重构，输出估计信号 $\bar{x}(t)$ ，这就是去噪后得到的“干净”信号。

进行阈值处理的时候需要选用合适的阈值函数，常用的阈值函数包括硬阈值函数、软阈值函数和半软阈值函数。下面我们将分别说明这三种阈值函数。

其中，硬阈值函数的表达式为公式(3-2)：

$$\bar{w}_{j,k} = \begin{cases} w_{j,k}, & |w_{j,k}| \geq \lambda \\ 0, & |w_{j,k}| < \lambda \end{cases} \quad (3-2)$$

软阈值函数表达式由公式(3-3)描述：

$$\bar{w}_{j,k} = \begin{cases} \text{sgn}(w_{j,k})(|w_{j,k}| - \lambda), & |w_{j,k}| \geq \lambda \\ 0, & |w_{j,k}| < \lambda \end{cases} \quad (3-3)$$

硬阈值函数处理过的小波系数在 $\pm\lambda$ 处会出现不连续的现象，所以会在信号重构的过程中造成问题；软阈值函数处理的小波系数相对更平顺一些，但小波估计系数即 $\bar{w}_{j,k}$ 与原始系数之间关系不够稳定，这直接影响了信号的重构，造成边缘数据失真的

问题。因此，研究人员提出了半软阈值函数，该处理函数介于软阈值函数和硬阈值函数之间，继承了二者的优点，其表达式为：

$$\bar{w}_{j,k} = \begin{cases} \text{sgn}(w_{j,k}) \left(|w_{j,k}| - \lambda \right) + \frac{2\lambda}{1 + e^{2w_{j,k}/\lambda}}, & |w_{j,k}| \geq \lambda \\ 0, & |w_{j,k}| \leq \lambda \end{cases} \quad (3-4)$$

其中，公式(3-2)、公式(3-3)和公式(3-4)中的 λ 代表阈值， $w_{j,k}$ 代表小波系数， $\bar{w}_{j,k}$ 代表小波估计系数，公式(3-4)中的 $\text{sgn}()$ 代表符号函数。

小波阈值去噪算法是一种容易实现并且效果较好的去噪方法，因此小波阈值去噪的研究热点之一就是选择一个合适的阈值。文献[62]中提出了一种新的阈值选择算法，计算阈值的方法如下：

$$\lambda[k] = \hat{\sigma}[k] \cdot \lambda_{SURE}[k] \quad (3-5)$$

式中， $\hat{\sigma}[k]$ 是一个缩放因子，它估计了去除干扰信号之后的接收信号的标准偏差； $\lambda_{SURE}[k]$ 是无缩放的门限函数，它由一个自适应门限函数得到，作者提出的这种阈值选择算法可以高效地筛选出合适的阈值。

在本文中，我们选择 MATLAB 小波工具箱提供的 WDEN 去噪函数来消除 CSI 信号中的噪声，最终，我们可以得到去噪之后平滑的 CSI 数据曲线。

此外，尽管主成分分析法在许多其他工作中被用来消除噪声，但它更常用的场景是高维数据的降维，并通过主成分分析法提取数据的主要特征组成部分。然而，在我们所设计的框架中，数据的每一个维度对于得到一个优秀的结果都是至关重要的，这表明在我们的工作中不需要降维。

为了验证小波去噪的效果，我们从接收机接收到的 30 个子载波中随机选取了几个子载波来绘制去噪前和去噪后的 CSI 数据曲线来观察小波去噪算法在我们数据中的实际表现效果。由于绘制全部子载波数据曲线图工作量过多且无需这样做，为了说明问题，本文仅以第 29 个子载波上的数据为例，分别绘制了未经处理和使用不同阈值函数的小波去噪算法去噪后的 CSI 曲线，分别如图 3-16、图 3-17、图 3-18 和图 3-19 所示。其中，图 3-16 为含有噪声信号的原始信号，图 3-17 为使用固定阈值函数实施去噪后的效果，图 3-18 为使用硬阈值函数实施去噪后的效果，图 3-19 为使用软阈值函数实施去噪后的效果，从去噪后的信号曲线图中可以发现，虽然应用三种不同的阈值函数去噪的效果不尽相同，会有细节上的差异，但是总体上来看，大部分的噪声可以被消除，去噪后的 CSI 曲线变得更加平滑。




图 3-16 含有噪声信号的原始信号

由图 3-16 可知，原始信号中含有大量的噪声信号，如果直接使用原始数据会对实验结果的准确率造成很大的影响，所以必须先去除这些噪声信号才能进一步处理、分析和提取特征数据。




图 3-17 使用固定阈值去噪后的信号




图 3-18 使用硬阈值去噪后的信号

由图 3-17、图 3-18 和图 3-19 可知，使用硬阈值函数去噪比使用固定阈值函数去噪消除了更多的离群点，比如数据包编号 400 内的两个离群点，而使用软阈值函数去噪数据曲线表现得更加“舒展”，本文最终选择使用软阈值函数去噪，尽管软阈值函数去噪保留了部分离群点，但是离群点代表的的数据也是分析环境人数的重要依据之一，所以不能轻易舍弃这些离群点。




图 3-19 使用软阈值去噪后的信号

3.5 属性特征提取

数据经过降噪处理之后保留了原始波动，之后就可以开始提取特征进行分析，用于后续的人数检测和人员计数，检测环境中 CSI 数据曲线的波动幅度随着人员数量的变化会变化，提取的特征应该能够包含这样的信息，下面我们将分析并提取符合条件的特征。

3.5.1 分析 CSI 数据的常用特征

分析 CSI 数据时主要提取的特征有以下种类：

(1) 最小值(Min)和最大值(Max)：最小值和最大值分别代表了一组 CSI 数据中的两个极值，可以从一定程度上反映该组数据中人员动作幅度的大小和人数的不同。此外，最大值与最小值的差值被称为全距，表示数据的最大范围，这个指标的缺点是没有充分利用所有数据，从而导致结果偏差大。

(2) 平均值(Mean)：平均值可以在一定程度上反应数据的波动程度，可以使用平均值反映一组样本的总体状况。

(3) 四分位距(Interquartile Range, IQR)：指的是一组数据(按照大小排列)中四分之一位置和四分之三位置数据的差值，经常用于构建箱型图，该指标虽然避免了极端值的影响，但是仍然没有充分利用所有数据，此外，该值的一半被称为四分位差。

(4) 方差(Variance)：方差反映了一组数据中每个个体样本与整体平均值之间的平均区别。方差的大小代表着一组样本数据的稳定程度或波动程度。方差的计算方法如公式(3-6)所示：

$$Var = \frac{\sum_{i=1}^N (X_i - \mu)^2}{N} \quad (3-6)$$

式中， X_i 代表第*i*个样本点， μ 表示样本数据的平均值， N 是样本点的总数。此外，标准差就是方差的平方根。

(5) 方均根(Root Mean Square, RMS)：方均根指的是样本数据的平方和除以样本总数再开平方所得到的一个指标，该值可以反应数据的波动和离散程度，其计算方法如公式(3-7)所示：

$$RMS = \sqrt{\frac{\sum_{i=1}^N X_i^2}{N}} = \sqrt{\frac{X_1^2 + X_2^2 + \cdots + X_N^2}{N}} \quad (3-7)$$

式中， X_i 和 N 的含义与方差表达式中所述相同。

(6) 变异系数(Coefficient of Variation, CV): 变异系数是一组样本标准差和平均值倒数的乘积, 计算方法如公式(3-8)所示:

$$CV = \frac{\sigma}{\mu} \quad (3-8)$$

式中, σ 表示样本的标准差, μ 表示样本的平均值。

必须使用变异系数的场景是衡量不同数量级样本时的差异, 因为从变异系数的计算公式可以推断, 如果一组样本数据的标准差越大, 平均值越小, 那么这一组样本数据的变异系数就会越大, 因为这说明了每个个体样本间的差异很大, 不在相同的数量级上。

(7) 峭度(Kurtosis, K): 顾名思义, 该指标对于尖峰数据非常敏感, 用于描述随机变量的分布特性, 该指标是一个无量纲的指标, 峭度大的数据集通常具有离群值, 峭度小的数据集通常缺乏离群值, 峭度的计算方法如公式(3-9)所示:

$$K = \frac{E\{x - \mu\}^4}{\sigma^4} \quad (3-9)$$

(8) 偏度(Skewness, S): 偏度是描述一组数据非对称程度的指标特征, 偏度值在数量上有正负之分, 偏度为负(即负偏态或左偏态)表示对于平均值而言, 绝大多数样本位于其右侧; 相反情况下, 偏度为正(即正偏态或右偏态)表示对于平均值而言, 绝大多数样本位于其左侧。最后一种情况就是偏度为 0, 此时表示数据集中的样本点相对均匀地分布在平均值的两侧, 但并不意味着是对称分布, 比如正态分布的数据集偏度就是 0。偏度的计算方法如公式(3-10)所示:

$$S = \frac{E\{x - \mu\}^3}{\sigma^3} \quad (3-10)$$

3.5.2 人员计数特征提取

由上述分析可知, 首先, 最小值和最大值以及全距只是简单地使用了一组数据中的两个极值, 尽管它们可以在一定程度上反映数据的波动程度, 但是并不能代表数据的整体特征, 只是极少的部分特征, 所以并不适用于分析 CSI 数据的整体波动和离散程度; 其次, 变异系数的应用场景一般是比较不同数量级的数据在离散度方面的差异, 然而, 由图 3-5、图 3-6 和图 3-7 可知, 本实验中采集的 CSI 数据处于同一数量级, 虽然不同人数情况下的 CSI 数据表现出不同的波动程度, 但是他们的变异系数很小, 所以变异系数也不适合用于 CSI 数据波动程度的分析; 此外, 峭度和峰度一

般用于分析数据的分布情况而非波动程度,所以不适用于本文的研究;最后,四分位距虽然使用的也是数据中的两个值,但是并不是极值,有效避免了极端情况,因此可用于CSI数据波动程度的分析,平均值和方均根值反映着一组样本的整体状况,也可用于CSI数据波动程度的分析,方差定量地考虑了一组数据所有样本点与平均值的偏差程度,可以准确地反映一组数据的波动离散程度,因此方差是比较优秀的特征指标,适合本文的研究。

基于以上分析,结合本文核心思想:根据CSI测量值的波动离散程度来推断检测环境中的人员数量,因此,本文选择了以下特征作为进一步研究的训练特征,分别是方差、平均值、四分位距和方均根值。能够推断环境中人员数量的理想特征应该具有以下特点:首先,在相同人数下收集的CSI数据的特征应具有足够的稳定性,即检测环境中的人数不变时,CSI应当保持稳定而不是像RSSI那样出现剧烈波动的情况,同时,在不同人数下收集的CSI数据的特征应有所区别,也就是说,检测环境中的人数不同时,CSI数据应当表现出明显的可区分性,这样才能确保后续人数估计模型的准确性。前期准备工作完成之后,我们分别在从无人到最多四个人的情况下进行了实验,采集到大量的CSI数据,然后分别提取了接收天线上30个子载波的CSI数据的特征,并分别绘制了方差、平均值、四分位距和均方根值的曲线,如图3-20、图3-21、图3-22和图3-23所示。




图 3-20 30 个子载波上 CSI 数据的方差




图 3-21 30 个子载波上 CSI 数据的平均值




图 3-22 30 个子载波上 CSI 数据的四分位距

从以上各个特征值的曲线图中可以看出,当检测环境中没有人时,方差和四分位距都处于一个很低的水平且保持稳定,尤其是方差,而平均值和均方根值虽然有一定的波动,但是仍然相对稳定,这说明四个特征总体上可以描述无人环境;当检测环境

中有一个人时，四个特征值都开始有较大幅度的波动；随着人数的增多，特征值的波动逐渐开始变大，这说明所选的四个特征几乎满足了理想特征的特点，可以用于估计环境中的人数，但是当人数增加到三人和四人时，无法明显区分人数，所以接下来需要进一步使用机器学习算法对这些特征进行训练和分类，以获得更加准确的分类效果，这样就可以估计环境中的人员数量。




图 3-23 30 个子载波上 CSI 数据的方均根值

3.6 机器学习分类器

在选定并提取特征后，分别使用四种机器学习方法包括支持向量机、随机森林、K 近邻和决策树对特征数据进行训练和分类，由于特征数据的标签是根据不同的人数来标定，即检测环境中无人时对应的数据标签为 0，有 1 人时对应的标签为 1，以此类推，所以分类器最终输出的类数就是环境中的人数。

3.6.1 超参数调优

模型优化是机器学习和深度学习中极其重要的一步，而优化模型的主要手段就是对超参数进行调优，参数对于机器学习算法而言意义重大，不同的参数对结果的准确性也有很大的影响，参数寻优的过程就是找到使得机器学习算法在对测试集进行验证时性能表现最佳的超参数的过程。在对数据集进行训练之前，必须设置好合适的超参数才可以训练出准确的模型。

常用的超参数优化方法有三种,他们分别是手动调参、网格寻优(Grid Search, GR)和随机寻优(Random Search, RS)。手动调参依赖于研究人员的经验,有经验的工程师可以根据数据集的特点快速确定模型的超参数,手动调优是一个不断试错的过程,机械化且比较费时间,因此逐渐衍生出了自动化的超参数调优方法,网格搜索法就是最基本的一种超参数自动寻优,其本质是穷举原理,给定一个参数范围,算法会在该范围内搜索参数并形成多种参数组合,最终使用测试集数据误差最小且准确率最高的超参数组合,网格搜索法的缺点是当超参数规模较大时,算法的时间复杂度会急速增长,导致该方法寻优的效率变低^[63],所以超参数规模较大时更适合使用随机搜索的优化方法,可以弥补网格搜索的缺点。本文使用的机器学习方法经实际测试,使用网格搜索即可快速实现超参数调优,所以本文使用网格搜索法进行超参数调优。

使用四种机器学习算法对特征进行分类后,准确率最高的是 SVM,所以本文着重介绍 SVM 的参数调优过程。首先需要选择的是核函数 `kernal`,因为核函数的选择对于算法性能有着至关重要的作用,尤其是针对本文使用的这种线性不可分的 CSI 数据,可选参数有 RBF 高斯核函数、Linear 线性核函数、Poly 多项式核函数和 Sigmoid 核函数,其中,最常用的是线性核函数和高斯核函数,线性核函数用于线性可分数据,显然不适用于本文的研究,因为由前面的分析可知,在本文研究背景下,检测环境中的人数和采集的 CSI 数据之间并不是线性关系,而是复杂的非线性关系,而且从理论上讲高斯核函数的性能表现一定优于线性核函数,经过交叉验证和基于对数据集的先验知识,本文选择使用高斯核函数,这样可以得到更准确的模型;另一个需要调整的参数是惩罚系数 C,惩罚系数较大时,表明我们不想放弃离群点,可能会导致过拟合,惩罚系数较小时,表明我们愿意放弃离群点,本文最终确定惩罚系数的值为 4;如果我们选定了高斯核函数,参数 `gamma` 就会“与生俱来”,`gamma` 值的大小代表着支持向量的多少,而训练和预测模型的快慢受到支持向量数量的影响,本文最终选定的 `gamma` 值为 0.4。

3.6.2 分类器训练和分类

我们分别采集了环境中存在不同人数时的 CSI 数据,所以可以将本文工作转化为分类问题,输出类别的值即为检测环境中的人数,这样我们就可以通过最终的分

类结果获得估计的人数,这样做的好处是可以将人员数量与检测环境中采集的 CSI 数据之间的复杂非线性关系用分类的思想来模拟并实现人员计数。

本文主要使用 SVM 算法进行训练和分类，其余算法作为对比实验。SVM 是一种有监督的机器学习方法，使用核函数来解决非线性分类问题，可以达到满意的分类效果。传统的 SVM 只能处理两类情况。但在我们的框架中，要求分类算法能进行多次分类，并能处理线性不可分的数据集，所以无法直接使用传统的 SVM，因此需要做一定的改动。SVM 的多重分类可以通过“one vs the rest”的思想来实现，首先从数据集中分出一个类，其余的类都被归入另一个类，然后对剩下的类别重复同样的分类操作，直到所有 k 个类别被划分完成。最终，在这个过程中会构建 k 个分类器^[64]。

由于本文使用 python 的 scikit-learn 机器学习库实现机器学习算法，所以将特征数据设置成机器学习要求的数据格式，随后输入 SVM 进行训练和在线测试。对于不同数量人员的情况，分别处理了大量的样本以探索人的数量和 CSI 数据之间的关系，同时，根据测试结果不断改进模型的性能。

3.7 本章小结

本章主要介绍了本文设计的基于 CSI 的室内人员计数框架，首先从整体上概述了框架的主要组成模块，包括三个部分，分别是数据预处理模块、离线训练模块和在线验证模块。其中，在第一个模块中，首先是 CSI 数据的采集和幅值的提取，其次是最为关键的部分，也是本文主要创新点之一，即最优数据的筛选，不同于之前的研究，本文的研究建立在最优数据的基础之上，而非所有可用数据，这进一步保证了结果的准确性，然后本文使用离散小波变换对数据进行去噪处理。在第二个模块中，首先分析了常用特征的特点以及对于本文 CSI 数据的是适用性，然后分别选取了方差、平均值、均方根值和四分位距四个特征作为本文的特征，因为这些特征可以反映 CSI 数据的波动和离散程度，有利于分析环境中的人数。提取特征之后，分别使用支持向量机、随机森林、K 近邻和决策树机器学习算法对特征数据进行训练和分类，最终使用效果最好的支持向量机算法作为本文的最终结果。

第4章 实验方案架构与结果性能评估

4.1 实验方案架构设计

实验设备安装部署完毕之后,准备进行实验,为了模拟真实情况,本文选择的环境是实验室内某区域,该区域内布局示意图如图4-1所示,由图可知,室内环境较为复杂,除了门窗之外,还有大量的桌椅以及一些杂物,还原了真实场景。




图4-1 实验室内实验区域示意图

实验区域面积大小为 3.6×8.4 平方米,路由器和微型计算机都部署在距离地面高度为1米之处。本文使用 MATLAB 和 Python 3.8 来分析数据,Python 主要用于实现机器学习算法和评估分类器性能表现,本文主要使用 Scikit-learn 库实现机器学习算法。在实验过程中,我们分别邀请了1、2、3、4名实验人员进入检测区域,来回行走持续3分钟,由于发射器以50个数据包/秒的速度连续向接收器发送数据,因此每次实验采集数据 $50 \times 60 \times 3 = 9000$ 个数据包,共采集 $9000 \times 5 = 45000$ 个数据包。值得一提的是,每个实验人员都是随机选择的,也就是说,我们并不刻意关心实验人员的个人特征,包括身高、体重和身体状况,目的是使模型拥有更好的泛化能力。此外,

由于本文提出的框架是无设备检测，所以并不需要实验人员携带任何电子设备或电子标签，只需走进检测区域即可采集到 CSI 数据。

在实验中，使用了一台带有两根外部全向天线的 TP-LINK WR841N 路由器作为发射机，一台配备了英特尔 5300 网卡的电脑主机作为接收器，此外，该计算机的操作系统是 Ubuntu 14.04 LTS。在进行实验时，发射器以 50 个数据包/秒的速度连续向接收器发送数据。在收集的数据包中，每个数据包中的 CSI 数据是一个 $2 \times 3 \times 30$ 的三维复数矩阵，其中第一行和第二行分别代表第一根和第二根 TX 天线发送的数据。同时，第一列和第二列分别代表第一根和第二根 RX 天线接收的数据(这两个数字分别代表 TX1 和 TX2)，第三列代表第三根 RX 天线接收的数据^[65]。如上所述，不同通信链路上的信号质量表现出明显的差异。因此，我们最终选择了由第一个 TX 天线和第二个 RX 天线组成的链路的信号，这是我们筛选的泛化性能最好的数据。

4.2 实验结果性能评估

4.2.1 分类器性能评估

分类器的好坏主要有各种性能评估指标界定，常用的分类器性能评估指标主要包括精度(Accuracy)、查全率(Recall)、查准率(Precision)、F1 分数(F1 Score)、ROC 曲线、曲线下面积(Area Under the Curve, AUC)和 PR 曲线等，其中大部分性能评估指标都来源于混淆矩阵，混淆矩阵最初是用于评估解决二分类问题分类器性能的一种直观的表格式矩阵图^[66]，其结构如图 4-2 所示，现已推广到多分类器。

		预测类别	
		Positive	Negative
真实类别	Positive	TP	FN
	Negative	FP	TN

图 4-2 混淆矩阵结构示意图

由图 4-2 可知，最简单的混淆矩阵只有 1 和 0 两类，分别对应阳和阴，纵轴代表真实类别，横轴代表预测类别。当真实类别为 positive 且预测类别为 positive 时，对

应着结果 TP(True Positive); 当真实类别为 positive 且预测类别为 negative 时, 对应着结果 FN(False Negative); 当真实类别为 negative 且预测类别为 positive 时, 对应着结果 FP(False Positive); 当真实类别为 negative 且预测类别为 negative 时, 对应着结果 TN(True Negative)。由上述定义可知, TP 和 TN 代表我们的分类器预测正确的部分, 而 FN 和 FP 代表我们的分类器预测错误的部分, 所以对于我们的分类器而言, 我们希望其 TP 和 TN 越大越好, 这代表着预测结果为正确的类别越多, 而 FN 和 FP 越小越好, 这代表着预测结果为错误的类别越少^[67]。

由前述可知, 常用的分类器性能评价指标都是由混淆矩阵衍生而来, 所以基于以上四项数据 TP、FP、FN、TN 可以计算其他的性能评价指标,

其中, 准确率表示分类器正确分类样本占总样本(即所有类别)的比例, 准确率是最常用的分类器性能评价指标, 因为准确率的高低直接决定分类器是否能给出正确的分类结果, 其计算方法如公式(4-1)所示:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (4-1)$$

同时可知, 分类错误率为:

$$Errorrate = 1 - Accuracy \quad (4-2)$$

精确率(PPV, Positive Predicted Value), 又叫查准率, 表示在分类器预测的所有 positive 类别中预测正确的比例, 如果分类器的查准率这一指标比较高, 则代表着如果一个样本被预测为正例, 那么这个样本为正例的概率就很大, 该指标的计算方法如公式(4-3)所示:

$$Precision = \frac{TP}{TP + FP} \quad (4-3)$$

查全率(TPR, True Positive Rate), 又叫灵敏度或召回率, 表示在所有真实 positive 类别中分类器预测正确的 positive 所占的比例, 代表着分类器辨别正例的能力, 其计算方法如公式(4-4)所示:

$$Recall = \frac{TP}{TP + FN} \quad (4-4)$$

特异度(TNR, True Negative Rate), 表示在所有真实 negative 类别中分类器预测正确的 negative 类别所占的比例, 其计算方法如公式(4-5)所示:

$$Specificity = \frac{TN}{TN + FP} \quad (4-5)$$

在介绍 F1 分数(F1 Score)之前,首先需要说明 F 分数这一指标,因为实际上查全率和查准率这两个性能评估指标结合起来使用效果比较好,但是这两个指标各有所长,难以取舍,所以出现了 F 分数这一将二者结合起来的指标,其表达式如公式(4-6)所示:

$$F_{\alpha} = (1 + \alpha^2) \frac{Precision * Recall}{\alpha^2 * Precision + Recall} \quad (4-6)$$

由公式 4-6 可知,当 $\alpha > 1$ 时查全率有更大影响,当 $\alpha < 1$ 时查准率有更大影响。当 $\alpha = 1$ 时就得到了 F1 分数,此时 F1 分数就是查全率和查准率的调和平均数:

$$F_1 = \frac{2Precision * Recall}{Precision + Recall} \quad (4-7)$$

接收者操作特征曲线,又叫 ROC 曲线,最初用于信号检测领域,近年来在机器学习领域发展迅速,成为衡量分类器性能的一种重要手段,绘制 ROC 曲线需要引入真正率 TPR 和假正率 FPR 分别作为 ROC 曲线坐标图的纵轴和横轴,真正率即上文提到的召回率,假正率指的是在所有实际为阴性的样本中,被错误地判断为阳性所占的比例^[68],ROC 曲线示意图如图 4-3 所示。




图 4-3 ROC 曲线示意图

在如图 4-3 所示的 ROC 曲线中,对角线的虚线代表随机猜测模型的 ROC 曲线,此时的 TPR 和 FPR 相等,意味着猜测正确和猜测错误的概率相同,左上角的坐标点

(0,1)表示的是完美分类器，即每一个样本都能被准确预测为正确的类别。因此，分类器的 ROC 曲线越靠近左上角的“完美点”，表明分类器的性能越好，此外，图 4-3 中的蓝色部分即为 AUC 值，相应地，AUC 值越大则代表着分类器的性能越好，AUC 值必在 0~1 之间。

PR 曲线也是用于评估分类器性能的一个指标^[69]，其中，精确率 Precision 作为横坐标，召回率 Recall 作为纵坐标，值得注意的是，在 ROC 曲线上具有较高 AUC 值的分类器在 PR 曲线上也具有较高的 AUC 值。

本文首先分别绘制了四种机器学习算法下分类结果的归一化混淆矩阵，分别如图 4-4、图 4-5、图 4-6 和图 4-7 所示，混淆矩阵中横轴和纵轴均由 0、1、2、3、4 这五类组成，分别代表检测环境中人员的数量，观察混淆矩阵最直观的方法是看其对角线的颜色分布情况，颜色越深，数值越大，也代表着该类的分类准确率越高，其他区域的数字是某一类预测成其他类的比例。




图 4-4 使用支持向量机算法分类的混淆矩阵

由图 4-4 可知，使用支持向量机算法对特征数据进行分类的结果表现优秀，其中，对于检测环境中无人、有 1 人、有 2 人的识别率很高，都为 90%以上，并且可以百分百确认检测环境中是否有人，对于检测环境中 3 个人和 4 个人的情况，也

可以实现 70%以上平均约 75%的识别率，与此同时，SVM 算法的整体准确率高达 87.2%，由此可见，SVM 可以有效识别检测环境中的人数，此外，SVM 的精度、召回率和 F1 分数等其他性能指标具体情况如表 4-1 所示：

表 4-1 SVM 算法分类结果的精度、召回率和 F1 分数

	精度	召回率	F1 分数
class 0	1.00	1.00	1.00
class 1	0.83	0.94	0.88
class 2	0.96	0.93	0.94
class 3	0.92	0.79	0.85
class 4	0.64	0.70	0.67




图 4-5 使用随机森林算法分类的混淆矩阵

由图 4-5 可知，使用随机森林算法对特征数据进行分类的结果总体表现不如 SVM，具体来说，可以百分百确认检测环境中是否有人，对于检测环境中无人和有 1 人的情况，算法的识别率很高，可以达到平均约 94%的识别率，4 个人的情况略优于 SVM，但是到了 2 个人的情况时，相较于 1 人的情况，识别率下降大约为 0.1，3 个

人时再次大幅下降，并且接进 20%的概率将 3 人预测为 1 人，随机森林算法的整体准确率为 79.8%。此外，随机森林算法的精度、召回率和 F1 分数等其他性能指标具体情况如表 4-2 所示：

表 4-2 随机森林算法分类结果的精度、召回率和 F1 分数

	精度	召回率	F1 分数
class 0	1.00	1.00	1.00
class 1	0.67	0.88	0.76
class 2	1.00	0.81	0.90
class 3	0.88	0.50	0.64
class 4	0.50	0.80	0.62




图 4-6 使用 K 近邻算法分类的混淆矩阵

由图 4-6 可知，使用 K 近邻算法对特征数据进行分类的结果总体表现不如 SVM，其中，对于检测环境中无人、有 1 人和有 2 人的识别率很高，均超过了 90%，可以百分百确认检测环境中是否有人，但是 4 个人的情况识别率极低，只有 50%，这是难以令人接受的，K 近邻算法的整体准确率为 81.6%，略低于随机森林算法，大幅低

于 SVM。此外, K 近邻算法的精度、召回率和 F1 分数等其他性能指标具体情况如表 4-3 所示:

表 4-3 K 近邻算法分类结果的精度、召回率和 F1 分数

	精度	召回率	F1 分数
class 0	1.00	1.00	1.00
class 1	0.65	0.94	0.77
class 2	0.96	0.93	0.94
class 3	0.91	0.71	0.80
class 4	0.71	0.50	0.59




图 4-7 使用决策树算法分类的混淆矩阵

由图 4-7 可知, 使用决策树算法对特征数据进行分类的结果总体表现是四种机器学习算法中最差的, 整体准确率仅为 72.2%。其中, 对于检测环境中无人识别率依然为 100%, 而且有 1 人和有 2 人情况的识别率在四种机器学习算法中相比而言也很差, 至于三人和四人的情况, 识别率是最差的。此外, 决策树算法的精度、召回率和 F1 分数等其他性能指标具体情况如表 4-4 所示:

表 4-4 决策树算法分类结果的精度、召回率和 F1 分数

	精度	召回率	F1 分数
class 0	1.00	1.00	1.00
class 1	0.63	0.75	0.69
class 2	0.92	0.89	0.91
class 3	0.57	0.57	0.57
class 4	0.50	0.40	0.44

由以上分析可知，四种机器学习训练的模型总体准确率存在巨大差距，因此选用准确率最高的 SVM 算法模型作为本文的最终结果。进一步地，我们绘制了 SVM 模型分类结果的 ROC 曲线和 PR 曲线，分别如图 4-8 和图 4-9 所示。




图 4-8 SVM 模型分类结果的 ROC 曲线

从图 4-8 中的 ROC 曲线中可以发现，五个类别的 AUC(曲线下面积)值分别为 1.00、0.95、1.00、0.99、0.97，AUC 值越接近于 1，模型的性能就越好，这表明我们构建的分类器能够以很小的误差精确估计检测环境中的人数。同样，ROC 曲线越接近左上角的(0,1)点，分类器的分类效果就越好。

图 4-9 所示为代表精确度和召回率之间关系的 PR 曲线，由图可知，五个类别的曲线下面积分别为 1.00、0.93、0.99、0.95、0.82，只有人数为 4 的情况表现略差，其

余都在 0.9 以上, 同样地, 曲线下的面积越大, 说明分类器的效果越好, 这表明我们的分类器性能足够优秀, 可以有效估算检测环境中的人员数量。




图 4-9 SVM 模型分类结果的 PR 曲线

4.2.2 对比实验

除了分析我们提出的框架在人数估计方面的性能表现之外, 我们还将其与另一个名为 DeepCount 的人员计数方案进行了对比, DeepCount 是一个使用深度学习方法来估算室内环境中 WiFi 信号下人员数量的方案, DeepCount 使用的神经网络有两个隐藏层, 其中第一层有 300 个神经元, 第二层有 100 个神经元, 所以我们使用的网络结构和神经元数量与其保持一致。深度学习是机器学习的一个分支, 其核心逻辑是模拟人体神经网络, 建立不同神经元之间的“连接”, 学习输入数据的内在规律并预测新数据的规律, 深度学习现已被广泛应用于各个科研领域, 比如 CSI 环境感知领域的采用摄像头方案的视觉识别模块就需要使用卷积神经网络来实现图像分类, 深度学习具有其自身的优点, 然而, 深度学习需要花费大量的时间来训练模型, 这消耗了大量的计算资源。相反, 本文提出的框架在进行识别人数之前就已经选择了泛化性最好的数据即最优数据, 即使我们利用相对于深度学习而言更为“简单”的机器学习算法, 也可以获得较高的准确率, 并花费更少的时间, 因为机器学习中模型的训练更加快速。本文提出的人员计数框架和 DeepCount 方案的分类结果的混淆矩阵分别如

图 4-4 和图 4-10 所示。从图中可以看到，尽管 DeepCount 在人数为 4 的情况时表现优于我们的框架，但是我们提出的框架综合表现更好，准确率为 87.2%，而 DeepCount 方案的整体准确率为 82.4%。




图 4-10 DeepCount 方案分类结果的混淆矩阵

4.3 本章小结

本章主要介绍了本文的实验方案架构并对分类器的分类结果进行了性能评估。首先整体介绍了本文的实验环境，分析了该环境下对真实情况的还原，保证了实验结果的真实性和准确性，然后阐述了本文所用的采集 CSI 数据的硬件设备和处理数据的软件环境；接下来对实验结果进行了性能评估，首先介绍机器学习领域常用的用于评估算法性能的指标，包括混淆矩阵、准确率、精确率、召回率、特异度、F1 分数、ROC 曲线、AUC 值和 PR 曲线等，并分析了这些指标适用的情况，选取了本文所使用的性能评估指标，分别绘制了分类器分类结果的混淆矩阵、ROC 曲线和 PR 曲线，表明本文所提出的框架可以准确地估算检测环境中的人员数量，最后，将本文提出的人数估计框架与另一种人数估计方案 DeepCount 做了对比，对比结果表明本文所提出的框架准确率高于 DeepCount。

结 论

近年来随着 WiFi 基础设施的普及,无线网络几乎覆盖了生活的方方面面,这催生了无线感知技术的迅速发展,使其应用在多个领域。其中,应用非常广泛的无线感知应用之一就是室内环境下的人员计数,人员计数一般分为基于设备的和无设备的,无设备检测是更为方便和应用更为广泛的方案,发展前景广阔,本文使用的就是无设备感应的方案。

在本文中,我们提出了一个基于 CSI 的无设备人群计数框架,仅利用一个商用 WiFi 路由器和一台微型电脑主机就可以实现以非侵入性、低成本和精确的方式进行人员计数。该方案基于环境中人员数量和无线信号的映射关系提出,即在环境中活动的不同人数对 WiFi 信号有不同的影响,可以用 CSI 曲线来描述这种差异性的影响以探索人数和 CSI 信号之间的关系。因此本文首先使用 Intel 5300 网卡分别采集了不同人数下的 CSI 信号,随后提取了这些信号中的幅值信息。此外,我们的方案为了获得最佳结果,选择了泛化性最好的数据,即通过分析接收端三根天线接收到的 CSI 信号,并挑选在稳定环境中性能最佳的数据作为本文的分析数据。在采用和分析所收集的原始 CSI 数据之前,本文采用了 DWT 去噪方法来净化这些数据,结果表明,DWT 有效地去除了 CSI 信号中大部分噪声。去噪之后,我们分别提取了方差、平均值、四分位距和均方根值共四个特征分别作为支持向量机、随机森林、K 近邻和决策树等四种机器学习算法的输入进行进一步的训练和分类,值得一提的是,本文将“一对多”的分类方法用于 SVM 多分类,从而获得了所有四种机器学习算法方法中最好的分类结果。此外,本文还与另一个基于深度学习的人员计数方案进行了对比,结果显示本文框架表现更佳。

本文的主要研究内容总结如下:

- (1) 首先,我们提出了一个基于 CSI 的无设备人员计数框架,仅利用现有 WiFi 基础设施和一台微型计算机,以非侵入式、低成本和精确的方式对特定区域内的人员进行计数,无需额外的传感器和人员的主动参与,极大地提高了框架的适用性。
- (2) 其次,与其他利用所有提取的数据进行分析的方案不同,本文提出的框架提取数据并筛选表现最好的数据进行分析,这有效地减少了数据误差和算法计算成本,并且可以在精炼数据的基础上获得更准确的结果。

(3) 最后, 本文将人员计数问题转换为基于机器学习的分类问题。该框架引入了机器学习算法来训练特征并完成分类, 该框架由以下三个模块组成, 分别为信号预处理模块、离线训练模块和在线分类模块。

综上所述, 本文所提出的框架可以准确高效地实现检测环境中的人员计数, 但在实验过程中仍存在一些未经探索的问题, 在后续的研究工作中将对这些问题进行进一步的挖掘, 主要可以从以下两个方面进行思考:

(1) 环境中人数增多的影响。环境中人数增多会在一定程度上导致人数检测系统准确率的下降, 未来工作中需要结合其他技术开展研究, 这是本文将来值得探索的一个问题。

(2) 环境的影响。实验环境中存在着很多同一局域网中其他电子设备的干扰信号, 这些信号是否会对实验结果造成影响值得进一步的研究。

以上两个问题会在后续的科研工作中继续探讨。

参考文献

- [1] Gu F, Hu X, Ramezani M, et al. Indoor localization improved by spatial context—A survey[J]. ACM Computing Surveys (CSUR), 2019, 52(3): 1-35.
- [2] Zhang T, Song T, Chen D, et al. WiGrus: A WiFi-based gesture recognition system using software-defined radio[J]. IEEE Access, 2019, 7: 131102-131113.
- [3] Bet P, Castro P C, Ponti M A. Fall detection and fall risk assessment in older person using wearable sensors: A systematic review[J]. International Journal of Medical Informatics, 2019, 130: 103946.
- [4] Zou H, Zhou Y, Yang J, et al. Device-free occupancy detection and crowd counting in smart buildings with WiFi-enabled IoT[J]. Energy and Buildings, 2018, 174: 309-322.
- [5] Bedi G, Venayagamoorthy G K, Singh R. Development of an IoT-driven building environment for prediction of electric energy consumption[J]. IEEE Internet of Things Journal, 2020, 7(6): 4912-4921.
- [6] Spurny V, Pritzl V, Walter V, et al. Autonomous firefighting inside buildings by an unmanned aerial vehicle[J]. IEEE Access, 2021, 9: 15872-15890.
- [7] Prayag G, Hassibi S, Nunkoo R. A systematic review of consumer satisfaction studies in hospitality journals: Conceptual development, research approaches and future prospects[J]. Journal of Hospitality Marketing & Management, 2019, 28(1): 51-80.
- [8] Sikdar A, Zheng Y F, Xuan D. An iterative clustering algorithm for classification of object motion direction using infrared sensor array[C]//2015 IEEE International Conference on Technologies for Practical Robot Applications (TePRA). IEEE, 2015: 1-6.
- [9] Liu W, Salzmann M, Fua P. Estimating people flows to better count them in crowded scenes[C]//European Conference on Computer Vision. Springer, Cham, 2020: 723-740.
- [10] Ding H, Han J, Liu A X, et al. Human object estimation via backscattered radio frequency signal[C]//2015 IEEE Conference on Computer Communications (INFOCOM). IEEE, 2015: 1652-1660.
- [11] Zou H, Jiang H, Luo Y, et al. Bluedetect: An ibeacon-enabled scheme for accurate and energy-efficient indoor-outdoor detection and seamless location-based service[J]. Sensors, 2016, 16(2): 268.

- [12] Weppner J, Lukowicz P. Bluetooth based collaborative crowd density estimation with mobile phones[C]//2013 IEEE International Conference on Pervasive Computing and Communications (PerCom). IEEE, 2013: 193-200.
- [13] Wu C, Yang Z, Zhou Z, et al. Non-invasive detection of moving and stationary human with WiFi[J]. IEEE Journal on Selected Areas in Communications, 2015, 33(11): 2329-2342.
- [14] Yang Z, Zhou Z, Liu Y. From RSSI to CSI: Indoor localization via channel response[J]. ACM Computing Surveys (CSUR), 2013, 46(2): 1-32.
- [15] Liu J, Liu H, Chen Y, et al. Wireless sensing for human activity: A survey[J]. IEEE Communications Surveys & Tutorials, 2019, 22(3): 1629-1645.
- [16] Hagenaaers E, Pandharipande A, Murthy A, et al. Single-pixel thermopile infrared sensing for people counting[J]. IEEE Sensors Journal, 2020, 21(4): 4866-4873.
- [17] Wu L, Wang Y, Liu H. Occupancy detection and localization by monitoring nonlinear energy flow of a shuttered passive infrared sensor[J]. IEEE Sensors Journal, 2018, 18(21): 8656-8666.
- [18] Chidurala V, Li X. Occupancy estimation using thermal imaging sensors and machine learning algorithms[J]. IEEE Sensors Journal, 2021, 21(6): 8627-8638.
- [19] Tang N C, Lin Y Y, Weng M F, et al. Cross-camera knowledge transfer for multiview people counting[J]. IEEE Transactions on Image Processing, 2014, 24(1): 80-93.
- [20] Eshel R, Moses Y. Homography based multiple camera detection and tracking of people in a dense crowd[C]//2008 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2008: 1-8.
- [21] Yang J, Santamouris M, Lee S E. Review of occupancy sensing systems and occupancy modeling methodologies for the application in institutional buildings[J]. Energy and Buildings, 2016, 121: 344-349.
- [22] Bartsch J, Sperling Y, Bergmann R B. Efficient vision ray calibration of multi-camera systems[J]. Optics Express, 2021, 29(11): 17125-17139.
- [23] Weiss C, Kirmas A, Lemcke S, et al. Head tracking in automotive environments for driver monitoring using a low resolution thermal camera[J]. Vehicles, 2022, 4(1): 219-233.
- [24] Bjorkqvist M, Paski J, Salonen J, et al. Studies on hysteresis reduction in thermally carbonized porous silicon humidity sensor[J]. IEEE Sensors Journal, 2006, 6(3): 542-547.
- [25] Wang F, Feng Q, Chen Z, et al. Predictive control of indoor environment using occupant number detected by video data and CO2 concentration[J]. Energy and Buildings, 2017, 145: 155-162.

- [26] Candanedo L M, Feldheim V. Accurate occupancy detection of an office room from light, temperature, humidity and CO₂ measurements using statistical learning models[J]. Energy and Buildings, 2016, 112: 28-39.
- [27] Jiang C, Masood M K, Soh Y C, et al. Indoor occupancy estimation from carbon dioxide concentration[J]. Energy and Buildings, 2016, 131: 132-141.
- [28] Zhou R, Hou H, Gong Z, et al. Adaptive device-free localization in dynamic environments through adaptive neural networks[J]. IEEE Sensors Journal, 2020, 21(1): 548-559.
- [29] Patwari N, Hero A O, Perkins M, et al. Relative location estimation in wireless sensor networks[J]. IEEE Transactions on Signal Processing, 2003, 51(8): 2137-2148.
- [30] Ding H, Han J, Liu A X, et al. Counting human objects using backscattered radio frequency signals[J]. IEEE Transactions on Mobile Computing, 2018, 18(5): 1054-1067.
- [31] Li W, Su Z, Li R, et al. Abnormal crowd traffic detection for crowdsourced indoor positioning in heterogeneous communications networks[J]. IEEE Transactions on Network Science and Engineering, 2020, 7(4): 2494-2505.
- [32] Zhou R, Lu X, Fu Y, et al. Device-free crowd counting with WiFi channel state information and deep neural networks[J]. Wireless Networks, 2020, 26(5): 3495-3506.
- [33] Xi W, Zhao J, Li X Y, et al. Electronic frog eye: Counting crowd using WiFi[C]//IEEE INFOCOM 2014-IEEE Conference on Computer Communications. IEEE, 2014: 361-369.
- [34] Ibrahim O T, Gomaa W, Youssef M. CrossCount: A deep learning system for device-free human counting using WiFi[J]. IEEE Sensors Journal, 2019, 19(21): 9921-9928.
- [35] Larsson E G, Edfors O, Tufvesson F, et al. Massive MIMO for next generation wireless systems[J]. IEEE Communications Magazine, 2014, 52(2): 186-195.
- [36] Gesbert D, Shafi M, Shiu D, et al. From theory to practice: An overview of MIMO space-time coded wireless systems[J]. IEEE Journal on Selected Areas in Communications, 2003, 21(3): 281-302.
- [37] Lu L, Li G Y, Swindlehurst A L, et al. An overview of massive MIMO: Benefits and challenges[J]. IEEE Journal of Selected Topics in Signal Processing, 2014, 8(5): 742-758.
- [38] Armstrong J. OFDM for optical communications[J]. Journal of Lightwave Technology, 2009, 27(3): 189-204.
- [39] 刘冰凡, 陈伯孝. 基于 OFDM-LFM 信号的 MIMO 雷达通信一体化信号共享设计研究[J]. 电子与信息学报, 2019, 41(4): 801-808.

- [40] 谢尚佐, 李晋. 多跳 HF 无线电海平面传播损耗的研究[J]. 中国新通信, 2018, 20(14): 148.
- [41] 徐潇潇, 谢林柏, 彭力. 基于 WiFi 信号强度特征的室内定位系统设计[J]. 计算机工程, 2015, 41(4): 87-91.
- [42] 柯旭. 基于 WiFi 信号测量的人数估计方法研究[D]. 西安: 西安电子科技大学, 2017: 10-22
- [43] Wu R H, Lee Y H, Tseng H W, et al. Study of characteristics of RSSI signal[C]//2008 IEEE International Conference on Industrial Technology. IEEE, 2008: 1-3.
- [44] Yiu S, Dashti M, Claussen H, et al. Wireless RSSI fingerprinting localization[J]. Signal Processing, 2017, 131: 235-244.
- [45] 朱剑, 赵海, 孙佩刚, 等. 基于 RSSI 均值的等边三角形定位算法[J]. 东北大学学报(自然科学版), 2007, 28(8): 1094.
- [46] Wu K, Xiao J, Yi Y, et al. CSI-based indoor localization[J]. IEEE Transactions on Parallel and Distributed Systems, 2012, 24(7): 1300-1309.
- [47] Zhao Y, Liu S, Xue F, et al. DeepCount: Crowd counting with Wi-Fi using deep learning[J]. Journal of Communications and Information Networks, 2019, 4(3): 38-52.
- [48] Jordan M I, Mitchell T M. Machine learning: Trends, perspectives, and prospects[J]. Science, 2015, 349(6245): 255-260.
- [49] Carleo G, Cirac I, Cranmer K, et al. Machine learning and the physical sciences[J]. Reviews of Modern Physics, 2019, 91(4): 045002.
- [50] Liakos K G, Busato P, Moshou D, et al. Machine learning in agriculture: A review[J]. Sensors, 2018, 18(8): 2674.
- [51] El Naqa I, Murphy M J. What is machine learning?[M]//Machine Learning in Radiation Oncology. Springer, Cham, 2015: 3-11.
- [52] Kaelbling L P, Littman M L, Moore A W. Reinforcement learning: A survey[J]. Journal of Artificial Intelligence Research, 1996, 4: 237-285.
- [53] Cherkassky V, Ma Y. Practical selection of SVM parameters and noise estimation for SVM regression[J]. Neural Networks, 2004, 17(1): 113-126.
- [54] Guo G, Wang H, Bell D, et al. KNN model-based approach in classification[C]//OTM Confederated International Conferences" On the Move to Meaningful Internet Systems". Springer, Berlin, Heidelberg, 2003: 986-996.

- [55] Myles A J, Feudale R N, Liu Y, et al. An introduction to decision tree modeling[J]. Journal of Chemometrics: A Journal of the Chemometrics Society, 2004, 18(6): 275-285.
- [56] Biau G, Scornet E. A random forest guided tour[J]. Test, 2016, 25(2): 197-227.
- [57] Halperin D, Hu W, Sheth A, et al. Predictable 802.11 packet delivery from wireless channel measurements[J]. ACM SIGCOMM Computer Communication Review, 2010, 40(4): 159-170.
- [58] Qin S R, Zhong Y M. Research on the unified mathematical model for FT, STFT and WT and its applications[J]. Mechanical Systems and Signal Processing, 2004, 18(6): 1335-1347.
- [59] Torrence C, Compo G P. A practical guide to wavelet analysis[J]. Bulletin of the American Meteorological Society, 1998, 79(1): 61-78.
- [60] Chun-Lin L. A tutorial of the wavelet transform[J]. NTUEE, Taiwan, 2010, 21: 22.
- [61] Watson A B, Yang G Y, Solomon J A, et al. Visibility of wavelet quantization noise[J]. IEEE Transactions on Image Processing, 1997, 6(8): 1164-1175.
- [62] Chien Y R. Wavelet packet transform-based anti-jamming scheme with new threshold selection algorithm for GPS receivers[J]. Journal of the Chinese Institute of Engineers, 2018, 41(3): 181-185.
- [63] Liashchynskiy P, Liashchynskiy P. Grid search, random search, genetic algorithm: A big comparison for NAS[J]. ArXiv Preprint ArXiv:1912.06059, 2019.
- [64] Hsu C W, Lin C J. A comparison of methods for multiclass support vector machines[J]. IEEE Transactions on Neural Networks, 2002, 13(2): 415-425.
- [65] Halperin D, Hu W, Sheth A, et al. Tool release: Gathering 802.11 n traces with channel state information[J]. ACM SIGCOMM Computer Communication Review, 2011, 41(1): 53-53.
- [66] Townsend J T. Theoretical analysis of an alphabetic confusion matrix[J]. Perception & Psychophysics, 1971, 9(1): 40-50.
- [67] Luque A, Carrasco A, Martín A, et al. The impact of class imbalance in classification performance metrics based on the binary confusion matrix[J]. Pattern Recognition, 2019, 91: 216-231.
- [68] Hoo Z H, Candlish J, Teare D. What is an ROC curve?[J]. Emergency Medicine Journal, 2017, 34(6): 357-359.
- [69] Flach P, Kull M. Precision-recall-gain curves: PR analysis done right[J]. Advances in Neural Information Processing Systems, 2015, 28.

攻读硕士学位期间承担的科研任务与主要成果

(一)承担的科研任务

- [1] 应急环境下实时定位与无线网络资源优化协同设计, 国家自然科学基金项目, 课题编号: 61803328, 2019.01-2021.12, 参加。
- [2] 高动态环境下车联网信息可靠传输与资源优化管理, 国家自然科学基金项目, 编号: 61873223, 2020.11-至今, 参加。
- [3] 5G 无线蜂窝网络资源优化管理与安全传输, 河北省自然科学基金重点项目, 编号: F2019203095, 2020.11-至今, 参加。
- [4] 基于混合网络的工业协议融合技术及终端研发, 国家重点研发计划, 编号: 2020YFB1708700, 2020.11-至今, 参加。
- [5] 电网指挥调度作业风险管控技术研究及工程应用, 工程项目, 2020.09-至今, 参加。

(二)发明专利

- [1] 刘志新, 杨红磊, 袁亚洲, 杨旭, 袁瑞贺. 一种基于多维特征融合的人员跌倒检测方法: 中国, 公开号: 112613388A. (已公开)

(三)学术论文

- [1] Liu Z, Yuan R, Yuan Y, et al. A Sensor-Free Crowd Counting Framework for Indoor Environments Based on Channel State Information[J]. IEEE Sensors Journal, 2022, 22(6): 6062-6071. (中科院 SCI 二区)
- [2] Wei S, Yuan Y, Yuan R, et al. A Novel Adaptive PTS Scheme for PAPR Reduction in OFDM System[C]//2020 Chinese Automation Congress (CAC). IEEE, 2020: 5811-5816.

致 谢

时光飞逝，三年的研究生生活转眼就要结束了，从研究生一年级的懵懵懂懂到研究生三年级的“身经百战”，在这个过程中我经历了巨大的成长，这离不开老师们的悉心指导以及朋友同学家人的帮助。

首先我要感谢我的导师刘志新老师，刘老师和蔼可亲，平易近人，对待工作一向是兢兢业业，辅导学生经验丰富，教育学生始终强调劳逸结合，这不仅是说说而已，课题室会定期组织体育活动，旨在帮助同学们强身健体。在与老师沟通交流的过程中就可以感受到老师的细致与认真。在论文写作过程中有任何的问题，刘老师都可以快速帮助学生解决；在学术调研过程中，刘老师可以给你准确清晰的科研方向；在学术问题的探讨过程中，刘老师可以犀利地指出学生存在的误区，正是在这一次次的讨论与交流中，我的学术水平才取得了长足的进步，感谢刘老师！

其次我要感谢的是袁亚洲老师，我能取得今天的进步，完全离不开袁老师的悉心指导和在生活中的照顾，袁老师不仅是学生们眼中的优秀老师，更是大家心中的好朋友，袁老师有着强大的感染力和亲和力，不仅给予学生科研上的耐心指导，还给予大家生活上的关照，我清楚地记得在我研二时，科研思路陷入了困境，袁老师和我多次交流并最终一同确定了一个研究思路，不仅如此，还给我购买了科研设备以及实验仪器，这对于我后续的帮助极大，我不仅完成了自己的科研任务，还发表了相应的学术成果，这离不开袁老师的帮助与指导，感谢袁老师！

我还要感谢课题室所有的师兄弟以及同门，是你们在我无助时及时给予了我帮助，让我走出阴影，感谢你们在生活中对我的无私帮助，更要感谢你们在科研上对我的帮助，每一次和大家的深入讨论与交流都让我受益匪浅，尽管大家的研究方向不尽相同，但是每个人身上都有各自的闪光点值得我学习，比如 PPT 制作、专利撰写、论文写作与排版、学习方法等技能，感恩相遇，祝你们一帆风顺，前程似锦，归来仍是少年，感谢你们！

此外，我要感谢我的家人和女朋友，虽然你们不能给我专业上的指导和帮助，但是你们在我生活中给与了我极大的帮助，硕士期间每个人都会面临压力，每当我遇到困难时，你们都会给我鼓励，每当我遇到挫折时，你们都会给我安慰，这让我能够一直走下去，没有放弃，感谢你们！最后，感谢国家的各种政策一直帮助我走得更远！